UNIVERSIDADE FEDERAL DO RIO DE JANEIRO
INSTITUTO DE COMPUTAÇÃO
CURSO DE BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO

CÁSSIO EMANUEL FERREIRA DA SILVA
KAYO BACELAR DE OLIVEIRA

DETECÇÃO DE ANOMALIAS CIBERNÉTICAS UTILIZANDO MODELOS DE LINGUAGEM DE LARGA ESCALA E INTELIGÊNCIA ARTIFICIAL EXPLICÁVEL

RIO DE JANEIRO
2026

CÁSSIO EMANUEL FERREIRA DA SILVA
KAYO BACELAR DE OLIVEIRA

DETECÇÃO DE ANOMALIAS CIBERNÉTICAS UTILIZANDO MODELOS DE LINGUAGEM DE LARGA ESCALA E INTELIGÊNCIA ARTIFICIAL EXPLICÁVEL

Trabalho de conclusão de curso de graduação apresentado ao Instituto de Computação da Universidade Federal do Rio de Janeiro como parte dos requisitos para obtenção do grau de Bacharel em Ciência da Computação.

Orientador: Prof. Gabriel Rodrigues Caldas de Aquino

RIO DE JANEIRO
2026

Nota: Não entrar com o título do trabalho na ficha catalográfica em caixa alta.

CIP - Catalogação na Publicação

R484t

Ribeiro, Tatiana de Sousa
Titulo / Tatiana de Sousa Ribeiro. -- Rio de Janeiro, 2018.
44 f.

Orientador: Maria da Silva.
Trabalho de conclusão de curso (graduação) - Universidade Federal do Rio de Janeiro, Instituto de Matemática, Bacharel em Ciência da Computação, 2018.

1. Assunto 1. 2. Assunto 2. I. Silva, Maria da, orient. II. Titulo.

Elaborado pelo Sistema de Geração Automática da UFRJ com os dados fornecidos pelo(a) autor(a).

CÁSSIO EMANUEL FERREIRA DA SILVA
KAYO BACELAR DE OLIVEIRA

DETECÇÃO DE ANOMALIAS CIBERNÉTICAS UTILIZANDO MODELOS DE LINGUAGEM DE LARGA ESCALA E INTELIGÊNCIA ARTIFICIAL EXPLICÁVEL

Trabalho de conclusão de curso de graduação apresentado ao Instituto de Computação da Universidade Federal do Rio de Janeiro como parte dos requisitos para obtenção do grau de Bacharel em Ciência da Computação.

Aprovado em ___ de _____ de _____

BANCA EXAMINADORA:

Nome do Professor Orientador
Titulação (Instituição)

Nome do Professor1
Titulação (Instituição)

Nome do Professor2
Titulação (Instituição)

Dedicatória: Texto no qual o autor do trabalho oferece homenagem ou dedica o seu trabalho a alguém. Recomenda-se que o texto da dedicatória seja breve.
Deve ser começar na metade de página, ser localizada na parte inferior da página, alinhada à direita. A página ***não*** *deve conter o título "DEDICATÓRIA".*

AGRADECIMENTOS

Os agradecimentos devem ser dirigidos àqueles que contribuíram de maneira relevante à elaboração do trabalho, restringindo-se ao mínimo necessário, como instituições (CNPq, CAPES, UFRJ, empresas ou organizações que fizeram parte da pesquisa), ou pessoas (profissionais, pesquisadores, orientadores, etc.).

Os agradecimentos devem ser colocados de forma hierárquica de importância e para trabalhos financiados com recursos de instituições (CAPES, CNPq, FINEP, FAPERJ, etc.) os agradecimentos são obrigatórios a essas instituições.

Epígrafe: É um item onde o autor apresenta a citação de um texto que seja relacionado com o tema do trabalho, seguido da indicação de autoria do mesmo.
(texto iniciando do meio da página alinhado à direita)

"Few are those who see with their
own eyes and feel with their own hearts."

Albert Einstein
(Nome do autor da epígrafe)

RESUMO

Este trabalho propõe uma arquitetura de detecção de anomalias cibernéticas fundamentada em Modelos de Linguagem de Larga Escala (LLMs) para atenuar as limitações operacionais dos Sistemas de Detecção de Intrusão (IDS) baseados em assinaturas estáticas. O objetivo central consiste em desenvolver um ecossistema cognitivo capaz de analisar registros de eventos de alta entropia e fornecer narrativas táticas por meio de Inteligência Artificial Explicável (XAI), visando a redução da fadiga de alertas em Centros de Operações de Segurança. O método adota uma estrutura de processamento em duas fases orquestrada pelo modelo de pesos abertos Gemma 2. A experimentação metodológica engloba a geração de um conjunto de dados empírico em ambiente de simulação isolado, contendo tráfego de autenticação de servidores com vetores de ataque simulados. Na primeira fase, o sistema aplica a técnica de instrução com poucos exemplos para destilar a semântica dos registros brutos, convertendo-os em um formato tabular flexível que dispensa o uso de expressões regulares determinísticas. Na segunda fase, o motor de inferência contextualiza o comportamento do usuário e utiliza a técnica de Cadeia de Raciocínio para avaliar a janela temporal de eventos. A análise dos resultados comprova que a arquitetura estrutura os dados com alta resiliência, preservando comandos complexos e cargas úteis. O motor analítico identifica com êxito ataques clássicos de força bruta externa e ameaças furtivas de origem interna, correlacionando varreduras de rede com as etapas táticas de reconhecimento da cadeia de ataque cibernético. O estudo conclui que a adoção de inteligência artificial generativa transforma a taxonomia da detecção defensiva, convertendo desvios comportamentais em auditorias forenses legíveis. Entretanto, o custo computacional associado à latência de processamento em hardware gráfico restringe a viabilidade da ferramenta como um mecanismo de prevenção em linha, consolidando seu valor tecnológico primário para investigações forenses assíncronas e triagem de incidentes.

Palavras-chave: inteligência artificial explicável; detecção de intrusão; modelos de linguagem de larga escala; segurança da informação; análise comportamental.

ABSTRACT

This work proposes a cyber anomaly detection architecture based on Large Language Models (LLMs) to mitigate the operational limitations of static signature-based Intrusion Detection Systems (IDS). The central objective consists of developing a cognitive ecosystem capable of analyzing high-entropy event logs and providing tactical narratives through Explainable Artificial Intelligence (XAI), aiming to reduce alert fatigue in Security Operations Centers. The method adopts a two-phase processing structure orchestrated by the open-weights model Gemma 2. The methodological experimentation encompasses the generation of an empirical dataset in an isolated simulation environment, containing server authentication traffic with simulated attack vectors. In the first phase, the system applies the few-shot prompting technique to distill the semantics of raw logs, converting them into a flexible tabular format that bypasses the use of deterministic regular expressions. In the second phase, the inference engine contextualizes user behavior and utilizes the Chain of Thought technique to evaluate the temporal window of events. The analysis of the results proves that the architecture structures the data with high resilience, preserving complex commands and payloads. The analytical engine successfully identifies classic external brute force attacks and stealthy internal threats, correlating network scans with the reconnaissance tactical stages of the cyber kill chain. The study concludes that the adoption of generative artificial intelligence transforms the taxonomy of defensive detection, converting behavioral deviations into readable forensic audits. However, the computational cost associated with processing latency in graphical hardware restricts the viability of the tool as an inline prevention mechanism, consolidating its primary technological value for asynchronous forensic investigations and incident triage.

Keywords: explainable artificial intelligence; intrusion detection; large language models; information security; behavioral analysis.

SUMÁRIO

1	**INTRODUÇÃO**	**10**
1.1	PROBLEMATIZAÇÃO	**10**
1.2	OBJETIVOS E JUSTIFICATIVA	**12**
1.3	PROPOSTA DE SOLUÇÃO	**13**
1.4	PRINCIPAIS CONTRIBUIÇÕES	**14**
1.5	ORGANIZAÇÃO DO TRABALHO	**14**
2	**FUNDAMENTAÇÃO TEÓRICA**	**16**
2.1	REGISTROS DE EVENTOS (*LOGS*) E AUDITORIA DE SEGURANÇA	**16**
2.2	GERENCIAMENTO DE *LOGS*: ECOSSISTEMA ELK E GRAYLOG	**17**
2.3	MODELOS DE LINGUAGEM DE LARGA ESCALA (LLMS)	**17**
2.4	INTELIGÊNCIA ARTIFICIAL EXPLICÁVEL (XAI)	**18**
2.5	SISTEMAS DE DETECÇÃO DE INTRUSÃO: ASSINATURA *VS.* COMPORTAMENTO	**19**
2.6	FASES DE UM ATAQUE E A *CYBER KILL CHAIN*	**19**
2.7	ENGENHARIA DE *PROMPT* E CADEIA DE RACIOCÍNIO (*CHAIN OF THOUGHT*)	**20**
3	**TRABALHOS RELACIONADOS**	**22**
3.1	CADEIA DE RACIOCÍNIO (*CHAIN OF THOUGHT*) EM LLMS	**22**
3.2	ANÁLISE DE *LOGS* E DETECÇÃO DE ANOMALIAS	**23**
3.3	EXPLICABILIDADE (XAI) NA SEGURANÇA DA INFORMAÇÃO	**23**
3.4	RESUMO COMPARATIVO DOS TRABALHOS RELACIONADOS	**24**
4	**PROPOSTA ARQUITETURAL E EXPLICABILIDADE**	**26**
4.1	PREMISSAS DE DESIGN E METODOLOGIA	**26**
4.2	COMPONENTES DETALHADOS DO SISTEMA	**26**
4.2.1	**Base de Dados Bruta (Ingestão)**	**26**
4.2.2	**Módulo de Padronização e Estruturação (LLM - Fase 1)**	**27**
4.2.2.1	**Repositório Intermediário de *Logs* Processados**	**28**
4.2.3	**Módulo de Triagem Quantitativa (Filtro Algorítmico)**	**28**
4.2.4	**Motor de Inferência e Decisão (LLM - Fase 2)**	**29**
4.2.5	**Painel de Resultados e Explicabilidade (XAI)**	**29**
4.3	FLUXO DE DADOS E TRANSFORMAÇÃO	**30**
5	**METODOLOGIA DE IMPLEMENTAÇÃO E AMBIENTE EXPERIMENTAL**	**31**
5.1	AMBIENTE DE DESENVOLVIMENTO E *HARDWARE*	**31**
5.2	SELEÇÃO DO MODELO: GEMMA 2	**32**

5.3 INGESTÃO DE DADOS E MODELAGEM DE CONTEXTO COMPORTAMENTAL 32
5.4 EXECUÇÃO DA FASE 1: DESTILAÇÃO SEMÂNTICA E ESTRUTURAÇÃO 33
5.5 EXECUÇÃO DA FASE 2: INFERÊNCIA CONTEXTUAL E EXPLICABILIDADE (XAI) 34
6 RESULTADOS E DISCUSSÕES 36
6.1 EFICÁCIA DA DESTILAÇÃO SEMÂNTICA (FASE 1) 36
6.2 AVALIAÇÃO DO MOTOR DE INFERÊNCIA E EXPLICABILIDADE 37
6.2.1 Cenário A: Detecção de Força Bruta Externa 37
6.2.2 Cenário B: Ameaça Interna e Reconhecimento 38
6.2.3 Cenário C: Triagem Quantitativa Algorítmica e Perfilamento Qualitativo 39
6.2.3.1 Etapa Quantitativa: Triagem por Análise de Frequência 40
6.2.3.2 Etapa Qualitativa: Perfilamento Contextual via LLM 41
6.3 AVALIAÇÃO QUANTITATIVA DE CLASSIFICAÇÃO 42
6.4 AVALIAÇÃO QUALITATIVA DA ARQUITETURA COGNITIVA . . 44
6.4.1 Fidelidade e Resiliência Semântica (Fase 1) 44
6.4.2 Aderência Tática a *Frameworks* de Segurança (Fase 2) 44
6.4.3 Qualidade da Explicabilidade e Redução de Carga Cognitiva . 45
6.5 DISCUSSÃO: POTENCIAIS E CUSTOS OPERACIONAIS 45
6.6 SÍNTESE DA EFETIVIDADE DO PIPELINE 46
7 CONSIDERAÇÕES FINAIS 47
7.1 ACHADOS PRÁTICOS 47
7.2 LIMITAÇÕES DO ESTUDO 48
7.3 TRABALHOS FUTUROS 48
REFERÊNCIAS 49

1 INTRODUÇÃO

A monitoração contínua de ativos computacionais é um requisito essencial para a segurança da informação e a resiliência de qualquer infraestrutura de tecnologia. No centro dessa estratégia estão os *logs* de eventos que, conforme definido pelo *National Institute of Standards and Technology* (*NIST*) (NIST, 2006), fornecem o histórico necessário para a auditoria de sistemas e a reconstrução cronológica de incidentes.

Entretanto, a análise desses registros enfrenta o desafio do volume massivo de dados gerados diariamente em ambientes corporativos e acadêmicos. Essa complexidade pôde ser observada na prática durante a atuação de um dos autores na infraestrutura de servidores e rede do Laboratório de Computação e Informática do Instituto de Computação (LCI/UFRJ), em 2022. Naquele período, foram registrados milhares de eventos e relatos de tentativas de acesso por força bruta direcionadas a serviços SSH da instituição, evidenciando como fluxos intensos de dados ruidosos sobrecarregam a análise e dificultam a identificação rápida de anomalias reais.

Esse cenário reflete um obstáculo recorrente na cibersegurança: o uso exclusivo de ferramentas baseadas em regras sintáticas ou inspeção manual torna-se limitado diante de volumes elevados de eventos. A partir dessa perspectiva prática e da necessidade de soluções mais adaptáveis, este trabalho une a vivência em infraestrutura de sistemas com o estudo de modelos de linguagem e segurança da informação, propondo o uso de inteligência artificial para auxiliar na triagem e na explicabilidade da análise de registros.

1.1 PROBLEMATIZAÇÃO

A urgência por soluções ágeis para detectar anomalias reflete-se diretamente na necessidade de evolução dos Sistemas de Detecção de Intrusão (*Intrusion Detection System* - IDS). Um IDS atua como um mecanismo de vigilância proativa que analisa eventos em tempo real para identificar violações de políticas de segurança ou ações maliciosas. Tradicionalmente, esses sistemas operam de duas formas principais: por meio de assinaturas pré-definidas (que funcionam como um banco de dados de ataques conhecidos) ou por métodos estatísticos, que buscam desvios em relação a um comportamento padrão.

Contudo, Sommer e Paxson (SOMMER; PAXSON, 2010) argumentam que tais abordagens apresentam dificuldades em lidar com *logs* não padronizados ou mensagens de texto livre. A grande dificuldade desses sistemas convencionais reside na rigidez de sua lógica de processamento. Por dependerem de regras sintáticas estritas ou modelos matemáticos quantitativos, eles falham ao processar registros que não seguem uma estrutura rígida. Isso ocorre porque o IDS convencional carece de capacidade de interpretação semântica; ele processa apenas cadeias de caracteres de forma literal e não compreende o contexto

ou o significado por trás de uma mensagem de sistema. Consequentemente, a natureza variável e subjetiva dos registros modernos torna-se um obstáculo para ferramentas que não possuem flexibilidade cognitiva para interpretar o conteúdo dos dados.

Para atenuar essa desestruturação, adotam-se soluções de centralização, formatação e padronização de *logs*, como o ecossistema *Elasticsearch, Logstash e Kibana* (ELK). Embora essas ferramentas sejam utilizadas para a organização visual e na busca indexada de grandes volumes de dados, elas operam em um nível estrutural. Elas preparam a informação, mas a responsabilidade de correlacionar eventos e extrair o real contexto semântico continua recaindo sobre analistas humanos ou sobre a criação manual de filtros complexos.

No entanto, o cenário de ameaças atual evoluiu para além de padrões fixos. O aumento de ataques sofisticados, como *Phishing* direcionado, *malwares* móveis e as Ameaças Persistentes Avançadas (*Advanced Persistent Threat* - APT), demonstra que invasores operam de forma furtiva, buscando mimetizar comportamentos legítimos. Segundo o relatório *Data Breach Investigations Report* (*DBIR*) da Verizon (Verizon, 2023), o abuso de credenciais e técnicas de engenharia social se apresentam como os vetores primários de intrusão, exigindo ferramentas capazes de identificar desvios comportamentais.

O grande desafio reside no fato de que essas ameaças, mesmo procurando um comportamento discreto, sem a geração de grandes quantidades de logs de registro, invariavelmente deixam indícios nos registros do sistema: os chamados Indicadores de Comprometimento (*Indicators of Compromise* - IoC) (JOHNSON et al., 2016). Tecnicamente, os IoCs constituem evidências digitais de uma intrusão, como endereços IP suspeitos, *hashes* de arquivos maliciosos ou padrões anômalos de execução de comandos. No contexto deste trabalho, os IoCs são importantes, pois representam os artefatos semânticos que devem ser extraídos e correlacionados pelo modelo de linguagem.

Diferente de sistemas convencionais e puramente estruturais, o uso de modelos de linguagem permite identificar "IoCs comportamentais": ações que, isoladamente, podem parecer inofensivas, mas que no contexto operacional sugerem o comprometimento do sistema. Seja um comando incomum disparado por um *script* de *malware* ou uma movimentação lateral após um acesso via *phishing*, esses sinais estão presentes nos *logs*. Mesmo quando estruturados por ferramentas de visualização, eles podem ser difíceis de detectar dado um grande volume de informações que podem ser gerados em um sistema. Métodos de filtragem — baseados em expressões regulares (*regex*), listas negras estáticas e lógica booleana determinística — falham em correlacionar esses eventos de forma semântica. Por dependerem de uma correspondência exata de caracteres (*string matching*), tais ferramentas são incapazes de interpretar a intenção por trás de uma variação sutil no comando ou de compreender o contexto histórico do usuário. Consequentemente, a rigidez sintática dessas abordagens permite que ataques sofisticados permaneçam ativos por longos períodos antes de serem identificados através de análises manuais ou reativas.

Nesse contexto, torna-se uma necessidade detectar tais anomalias nos estágios iniciais da cadeia de ataque (*Cyber Kill Chain* - CKC) para que se evite um aumento na abrangência do ataque. Este modelo, proposto por Hutchins, Cloppert e Amin (HUTCHINS; CLOPPERT; AMIN, 2011), descreve a sequência de etapas que um invasor deve percorrer para concluir uma intrusão com sucesso, iniciando-se pelo reconhecimento até a exfiltração final de dados. A importância estratégica de monitorar essa cadeia reside na possibilidade de interromper o avanço do ataque logo em suas primeiras etapas, mitigando riscos antes que o invasor atinja seus objetivos principais.

Identificar um comportamento suspeito nos primeiros sinais de execução pode ser determinante para conter um incidente antes que ele cause maiores danos. Quando essa identificação ocorre tardiamente, as consequências para uma organização podem incluir perda de dados, prejuízos financeiros e danos à sua reputação. Nesse contexto, os Modelos de Linguagem de Larga Escala (*Large Language Models* — LLMs), como o Gemma 2, surgem como uma alternativa para explorar novas abordagens na área de cibersegurança. Além da celeridade, esses modelos permitem lidar com a heterogeneidade dos registros, abstraindo variações de formato e sintaxe que confundiriam sistemas convencionais. Outro aspecto fundamental é a capacidade de *reasoning* (raciocínio), que permite à IA explicar o porquê de uma atividade ser suspeita, reduzindo a fadiga de alertas (*alert fatigue*) dos analistas humanos, um fenômeno onde o excesso de notificações compromete a eficácia operacional das equipes de defesa (AL-ALM et al., 2022).

O problema central que este trabalho aborda é, portanto, a incapacidade das análises tradicionais (caracterizadas por mecanismos de filtragem estática, dependência de assinaturas conhecidas e lógica booleana rígida) em identificar indícios de ataques modernos em tempo real. Propõe-se, como alternativa, o uso de inteligência artificial para realizar uma triagem semântica profunda. Esta análise é denominada profunda pois não se limita à comparação sintática, buscando interpretar a intenção do agente e a correlação entre eventos distintos. A vantagem estratégica reside na autonomia do sistema em processar diferentes formatos de *logs* sem intervenção humana constante para a criação de novas regras, tornando a detecção mais resiliente a variantes de ataques desconhecidos.

1.2 OBJETIVOS E JUSTIFICATIVA

A finalidade principal desta pesquisa é otimizar a produtividade e a precisão em centros de operações de segurança (*Security Operations Center* - SOC), fornecendo uma ferramenta capaz de identificar ameaças persistentes que operam de forma a não ser detectadas por ferramentas convencionais. Ao automatizar a triagem inicial e a correlação semântica de *logs*, o sistema visa reduzir o tempo de detecção, interrompendo a CKC antes que o invasor atinja seus objetivos finais.

A justificativa deste projeto fundamenta-se na necessidade crítica de mitigar os riscos

associados a ataques de *Phishing* e APTs, que podem resultar em prejuízos financeiros e reputacionais. Conforme preconizado por Gunning e Aha (GUNNING; AHA, 2019), a Inteligência Artificial Explicável (*Explainable Artificial Intelligence* - XAI) é um requisito essencial para que operadores humanos possam confiar e agir sobre as decisões da IA. Assim, o sistema proposto não apenas detecta o incidente, mas fornece justificativas textuais que permitem ao analista compreender a natureza da anomalia, diferenciando um acesso administrativo legítimo de uma tentativa de exfiltração de dados por um *malware* sofisticado.

1.3 PROPOSTA DE SOLUÇÃO

O presente trabalho propõe o desenvolvimento de um sistema de detecção de anomalias focado no comportamento do *host*, utilizando o modelo de linguagem de pesos abertos Gemma 2. Conforme demonstrado no relatório técnico da Google (Google, 2024), a arquitetura Gemma apresenta capacidades avançadas de compreensão de contexto e raciocínio lógico, tornando-a apta para processar dados técnicos que exigem alta capacidade de abstração.

A abordagem baseia-se na implementação de um ***pipeline* cognitivo** (GUDIVADA; BAEZA-YATES; RAGHAVAN, 2015) estruturado em duas etapas. Conforme a literatura de computação cognitiva, um *pipeline* desse tipo define-se como um fluxo de processamento de dados que incorpora capacidades interpretativas — tais como o processamento de linguagem natural, a contextualização semântica e a inferência lógica (*reasoning*) — para analisar e tomar decisões sobre informações desestruturadas. Diferente de sequências convencionais, voltadas estritamente a transformações sintáticas e limpezas matemáticas rígidas, a vertente cognitiva emula o discernimento interpretativo humano, adaptando-se a nuances e variações textuais que regras determinísticas falham em capturar.

Dentro desse fluxo, realiza-se primeiramente a normalização e a padronização dos *logs* brutos, onde metadados técnicos são convertidos em atributos contextuais inteligíveis, facilitando a identificação de padrões que indicariam etapas iniciais de uma intrusão. Em seguida, o modelo compara esses dados processados com o perfil histórico de atividades do usuário, permitindo uma classificação binária entre acessos legítimos e anômalos. O diferencial desta proposta reside na capacidade de lidar com a variabilidade semântica dos ataques modernos, oferecendo uma análise que vai além da simples comparação de *hashes* ou assinaturas fixas.

O diferencial central desta proposta reside na integração intrínseca da XAI e na sua superioridade analítica frente a soluções puramente estruturais. Enquanto ecossistemas tradicionais de mercado, como o ELK, atuam como repositórios e motores de busca, exigindo que um analista humano interprete painéis visuais e correlacione eventos manualmente —, o *pipeline* cognitivo automatiza esse esforço. A arquitetura não apenas

detecta a anomalia lidando com a variabilidade semântica dos ataques modernos, mas gera, em linguagem natural, uma justificativa detalhada para sua decisão. Esse nível de explicabilidade transforma dados brutos em inteligência acionável, permitindo que a equipe de operações compreenda imediatamente a natureza da ameaça, o que otimiza o tempo de resposta e atenua o impacto de falsos positivos.

1.4 PRINCIPAIS CONTRIBUIÇÕES

As principais contribuições deste trabalho de pesquisa são os seguintes:

- **Proposta** de uma arquitetura baseada em um *pipeline* cognitivo para detecção e análise de comportamentos anômalos em *logs* de sistemas.
- **Desenvolvimento** de uma estratégia híbrida de detecção, que combina métodos estatísticos de identificação de comportamentos atípicos com a capacidade de interpretação contextual de um LLM.
- **Implementação de um protótipo** com aplicação do modelo Gemma 2 na análise contextual de *logs*.
- **Avaliação experimental** através de experimentos em cenários de ameaças internas e externas com o objetivo de analisar a capacidade de identificação de comportamentos anômalos e a qualidade das justificativas produzidas.

1.5 ORGANIZAÇÃO DO TRABALHO

O restante desta monografia está estruturado da seguinte forma: o **Capítulo 2** apresenta a fundamentação teórica, detalhando a natureza dos registros de eventos (*logs*), as limitações do ecossistema ELK, os paradigmas de detecção de intrusão, as fases da *Cyber Kill Chain* e os princípios de Modelos de Linguagem de Larga Escala (LLMs) e Inteligência Artificial Explicável (XAI). O **Capítulo 3** expõe os trabalhos relacionados, situando a pesquisa no estado da arte referente ao uso da técnica de *Chain of Thought* e à explicabilidade na segurança da informação.

O **Capítulo 4** descreve a proposta arquitetural agnóstica baseada em um *pipeline* cognitivo de duas fases. Em seguida, o **Capítulo 5** detalha a metodologia de execução no ambiente de simulação, abordando desde a orquestração do processamento em lotes e engenharia de *prompt* na Fase 1, até a parametrização de inferência contextual na Fase 2 utilizando o modelo Gemma 2.

O **Capítulo 6** apresenta e discute os resultados empíricos, demonstrando a eficácia da arquitetura através de cenários de ameaças internas e externas, validação operacional por triagem híbrida quantitativa e avaliação qualitativa das justificativas geradas, além

de debater os custos operacionais da infraestrutura. Por fim, o **Capítulo 7** consolida as considerações finais, mapeia as limitações da tecnologia atual e propõe diretrizes para trabalhos futuros.

2 FUNDAMENTAÇÃO TEÓRICA

Para a compreensão aprofundada da arquitetura e das soluções propostas neste trabalho, neste capítulo são apresentados os fundamentos teóricos que norteiam o cruzamento entre a segurança da informação e a inteligência artificial. Este capítulo dedica-se a explorar os conceitos fundamentais que compõem o cenário de monitoramento de ameaças modernas. Inicialmente, abordam-se a natureza dos registros de eventos (*logs*) e as limitações das ferramentas tradicionais de estruturação de dados. Em seguida, o texto aborda as capacidades dos Modelos de Linguagem de Larga Escala (LLMs) e na importância da Inteligência Artificial Explicável (XAI) para mitigar a assimetria informacional em Centros de Operações de Segurança.

2.1 REGISTROS DE EVENTOS (*LOGS*) E AUDITORIA DE SEGURANÇA

No contexto da computação e segurança da informação, um registro de eventos, comumente denominado *log*, é a documentação cronológica, gerada de forma automática, das atividades e operações que ocorrem dentro de um sistema operacional, rede ou aplicação. Segundo as diretrizes do *National Institute of Standards and Technology* (NIST) (NIST, 2006), o gerenciamento de *logs* é fundamental para assegurar a rastreabilidade, a responsabilização e a reconstrução histórica de incidentes de segurança.

Esses arquivos centralizam os registros de operação da infraestrutura de TI corporativa. Cada evento significativo — como uma tentativa de autenticação, o escalonamento de um privilégio de usuário, a abertura de uma porta de rede ou a falha na execução de um *script* — gera uma entrada de texto. Uma entrada de *log* típica contém metadados, que incluem, no mínimo: o carimbo de tempo (*timestamp*) do evento, o endereço IP de origem e destino, o agente causador da ação (usuário ou processo) e a descrição técnica do resultado da operação.

A importância dos *logs* na cibersegurança moderna reside na sua capacidade de conter Indicadores de Comprometimento (*Indicators of Compromise* - IoC). IoCs são fragmentos de dados forenses — como a presença de um arquivo executável malicioso, um endereço IP com má reputação ou uma sequência incomum de falhas de *login* — que sugerem, com alto grau de confiança, que a rede ou o *host* foi violado. A detecção precoce de anomalias depende da habilidade de ler, processar e correlacionar essas cadeias de caracteres em meio a milhões de registros cotidianos legítimos. Contudo, a alta variabilidade sintática (formatos distintos entre fabricantes de *software*) e o volume massivo característico de ambientes corporativos tornam a análise manual de *logs* uma tarefa inviável.

2.2 GERENCIAMENTO DE *LOGS*: ECOSSISTEMA ELK E GRAYLOG

Para lidar com o volume e a entropia dos dados brutos mencionados na seção anterior, a indústria de segurança consolidou o uso de soluções de *Security Information and Event Management* (SIEM) e motores de busca centralizados. Entre as abordagens contemporâneas mais proeminentes, destacam-se o ecossistema ELK (composto por *Elasticsearch, Logstash* e *Kibana*) e o *Graylog*.

O ecossistema ELK atua segmentando o processamento da informação: o *Logstash* ingere e estrutura os dados por meio de expressões regulares (*regex*), o *Elasticsearch* indexa as informações para buscas em alta velocidade, e o *Kibana* provê a interface gráfica. De forma análoga, o ***Graylog*** consolidou-se como uma plataforma sólida focada na ingestão, roteamento e emissão de alertas. Utilizando motores como *Elasticsearch* ou *OpenSearch* em sua base estrutural, o Graylog facilita a criação de fluxos de dados (*streams*) e a extração de campos críticos por meio de regras de *pipeline* e extratores.

A adoção dessas plataformas resolve o desafio de infraestrutura: elas centralizam gigabytes de texto e permitem pesquisas em frações de segundos. No entanto, ambas as abordagens apresentam limitações ao paradigma determinístico, o que as torna insuficientes para a proposta deste trabalho.

O primeiro limitador é a fragilidade sintática. Ferramentas como Graylog e Logstash dependem fortemente de regras estáticas e expressões regulares pré-configuradas. Se uma aplicação sofrer uma atualização e alterar minimamente a formatação do seu *log*, a expressão regular falhará em extrair as entidades corretas, resultando na quebra do *pipeline* e na perda de visibilidade.

O segundo e limitador é a ausência de compreensão semântica. O Graylog é desenhado para buscar palavras-chave e disparar alertas binários quando um limite métrico é atingido (por exemplo, alertar se a palavra "falha"ocorrer 50 vezes em um minuto). Contudo, ele atua puramente como um indexador. O sistema não possui a flexibilidade cognitiva para correlacionar eventos temporalmente distantes e inferir a intenção de um usuário que, possuindo credenciais legítimas, inicia um mapeamento anômalo de rede.

Consequentemente, ferramentas como o Graylog alertam que um limite foi cruzado, mas o ônus da interpretação, de separar o que é um ruído operacional de um ataque de movimentação lateral, continua recaindo sobre o operador humano. Essa limitação estrutural justifica a necessidade de acoplar Motores de Inferência baseados em LLMs, transpondo a barreira da indexação para alcançar a Inteligência Artificial Explicável (XAI), entregando o contexto e a narrativa da ameaça mastigados para a equipe de segurança.

2.3 MODELOS DE LINGUAGEM DE LARGA ESCALA (LLMS)

Os Modelos de Linguagem de Larga Escala (*Large Language Models* - LLMs) representam um marco na evolução do Processamento de Linguagem Natural (PLN) e da

Inteligência Artificial. Fundamentados majoritariamente na arquitetura *Transformer*, introduzida por Vaswani *et al.* (VASWANI et al., 2017), esses modelos distinguem-se pela capacidade de processar sequências de texto em paralelo e capturar dependências de longo alcance por meio de mecanismos de "atenção"(*self-attention*). Esse mecanismo matemático permite que o modelo pondere a relevância de cada fragmento de texto (ou *token*) em relação a todos os outros na mesma entrada, garantindo uma compreensão holística do contexto.

Diferente das ferramentas baseadas em correspondência exata de caracteres (*string matching*) ou expressões regulares determinísticas, os LLMs não buscam apenas palavras-chave isoladas. Eles mapeiam representações vetoriais de alta dimensionalidade que capturam o significado semântico intrínseco das sentenças. No contexto técnico da cibersegurança, essa flexibilidade cognitiva permite que o modelo analise registros de eventos heterogêneos e identifique ações maliciosas, mesmo quando um invasor altera deliberadamente a sintaxe de um comando para evadir mecanismos de detecção estruturais.

Além da alta capacidade de processamento de texto, as gerações mais recentes de modelos de pesos abertos foram profundamente refinadas para executar tarefas de inferência e raciocínio lógico (*reasoning*). Isso permite que o LLM ultrapasse a barreira da simples formatação, sendo capaz de deduzir a intenção por trás de uma sequência temporal de eventos sistêmicos e categorizar comportamentos anômalos com base no contexto operacional estabelecido.

2.4 INTELIGÊNCIA ARTIFICIAL EXPLICÁVEL (XAI)

Apesar do poder analítico e preditivo dos modelos baseados em redes neurais profundas, sua adoção sistêmica em ambientes operacionais críticos, como os Centros de Operações de Segurança (SOC), esbarra frequentemente no dilema analítico conhecido como "caixa-preta"(*black-box*). Tradicionalmente, sistemas avançados de *Machine Learning* aplicados à detecção de intrusão recebem matrizes de dados de entrada e produzem classificações numéricas de precisão (por exemplo, atribuindo uma probabilidade de ataque de 95%), mas são incapazes de articular as premissas lógicas que fundamentaram tal conclusão.

A Inteligência Artificial Explicável (*Explainable Artificial Intelligence* - XAI) consolida-se como a disciplina acadêmica e prática voltada a mitigar esta opacidade. Conforme delineado pelo programa de pesquisas da *Defense Advanced Research Projects Agency* (DARPA), sumarizado por Gunning e Aha (GUNNING; AHA, 2019), o objetivo primordial da XAI é projetar e implementar sistemas cujos modelos computacionais e decisões possam ser interpretados, validados e confiados por operadores humanos especialistas. Em um cenário contínuo de defesa cibernética, a transparência algorítmica não é um mero refinamento metodológico, mas um requisito operacional.

Quando um analista humano recebe uma notificação binária desprovida de contexto, ele é submetido ao esforço cognitivo de investigar manualmente os *logs* subjacentes para validar a veracidade da ocorrência. Essa carga de trabalho repetitiva consome recursos e exacerba a fadiga de alertas (*alert fatigue*). A integração dos preceitos de XAI inverte esse paradigma ineficiente: o sistema de detecção não atua apenas como um alarme, mas como um assistente de triagem que provê uma narrativa baseada em evidências. Ao utilizar as capacidades generativas dos LLMs para descrever em linguagem natural a anomalia (destacando o agente infrator, as etapas de execução e a técnica evaziva observada) o sistema constrói uma ponte sólida de confiança entre o julgamento computacional e a tomada de decisão humana, propiciando ações de contenção e resposta a incidentes de forma rápida e precisa.

2.5 SISTEMAS DE DETECÇÃO DE INTRUSÃO: ASSINATURA *VS.* COMPORTAMENTO

A evolução das metodologias de detecção de ameaças divide-se historicamente em dois paradigmas fundamentais: a detecção baseada em assinaturas e a detecção baseada em anomalias comportamentais.

Sistemas tradicionais operam sob o modelo de assinaturas, comparando o tráfego de rede ou registros de eventos contra um banco de dados estático de ameaças conhecidas (semelhante ao funcionamento clássico de um antivírus). Embora esse método seja computacionalmente leve e possua baixas taxas de falsos positivos para ataques preexistentes, ele é inerentemente reativo. Ataques de "dia zero"(*zero-day*) ou táticas que utilizam credenciais legítimas roubadas não possuem uma assinatura prévia, tornando-se invisíveis para esses sensores.

Em contrapartida, a detecção baseada em anomalias e comportamento não procura pelo "mal conhecido", mas sim pelo "desvio do normal". Ao estabelecer uma linha de base (*baseline*) das atividades cotidianas de um usuário ou infraestrutura — como horários de acesso, volume de dados transferidos e comandos típicos executados — o sistema torna-se capaz de sinalizar ações inéditas ou suspeitas. O desafio histórico dessa abordagem, contudo, é a alta taxa de falsos positivos, exigindo o emprego de algoritmos cognitivos avançados para distinguir entre uma simples mudança de rotina de um funcionário e uma intrusão maliciosa.

2.6 FASES DE UM ATAQUE E A *CYBER KILL CHAIN*

Para padronizar a compreensão tática de incidentes cibernéticos, foram adotados modelos de categorização de ameaças, sendo a *Cyber Kill Chain* (desenvolvida pela Lockheed Martin) e o *framework* MITRE ATT&CK os mais proeminentes. Esses modelos concei-

tuais descrevem as etapas sequenciais que um adversário deve percorrer para concluir seu objetivo com sucesso.

A intrusão raramente é um evento singular, mas sim um processo metodológico. As fases primárias incluem o **Reconhecimento** (*Reconnaissance*), que se caracteriza pela coleta sistemática de informações e mapeamento da infraestrutura do alvo. Do ponto de vista comportamental, essa etapa é frequentemente identificada pelo uso de ferramentas de varredura de portas (como o Nmap) para descobrir serviços expostos, topologia de rede e vulnerabilidades ativas. Para converter essa descoberta em um acesso inicial, vetores como o ataque de **Força Bruta** (*Brute Force*) são constantemente empregados. Essa técnica caracteriza-se pela submissão massiva e automatizada de dicionários de senhas, deixando um rastro evidente de falhas de autenticação consecutivas nos registros (*logs*) do sistema em curtos intervalos temporais.

Uma vez que o acesso inicial é obtido, o ataque evolui para fases internas. A **Movimentação Lateral** (*Lateral Movement*) caracteriza-se pelo uso do *host* inicialmente comprometido como uma base de lançamento (*pivot*) para explorar, autenticar e infectar outras máquinas dentro da mesma rede interna. Na prática analítica, essa movimentação é evidenciada pela abertura indevida de terminais interativos (*shells*) e acessos anômalos a ativos adjacentes usando credenciais muitas vezes legítimas, visando escalar privilégios e alcançar sistemas críticos. Compreender estas fases operacionais é essencial para a auditoria de segurança, pois permite aos defensores identificar a progressão de um ataque em seus estágios iniciais, interrompendo a "cadeia de abate"antes da exfiltração de dados — processo final que consiste na transferência não autorizada, cópia ou roubo de informações corporativas sensíveis para um ambiente externo controlado pelos invasores.

2.7 ENGENHARIA DE *PROMPT* E CADEIA DE RACIOCÍNIO (*CHAIN OF THOUGHT*)

A integração de Modelos de Linguagem de Larga Escala (LLMs) em processos lógicos computacionais introduziu a necessidade de novas disciplinas de otimização, centralizadas na Engenharia de *Prompt* (*Prompt Engineering*). Diferente da programação clássica, onde se escreve código imperativo, a Engenharia de *Prompt* consiste no desenho estruturado de instruções em linguagem natural que condicionam as respostas de uma rede neural, extraindo o comportamento desejado e inibindo a geração de saídas imprevisíveis.

Dentro deste escopo, a técnica de *Few-Shot Prompting* (Instrução com Poucos Exemplos) atua como um mecanismo crítico de alinhamento estrutural. Ao fornecer ao modelo não apenas regras abstratas, mas pares concretos de entradas e saídas esperadas dentro da mesma janela de contexto, a ferramenta ajusta sua formatação sintática por imitação imediata, garantindo alta fidelidade na padronização de dados. Além da formatação, o comportamento do modelo é norteado pelo hiperparâmetro de Temperatura (*Temperature*), uma métrica estocástica que define o nível de criatividade da inteligência artificial:

valores próximos a zero forçam o modelo a convergir sempre para a resposta matematicamente mais provável, garantindo o rigor e a reprodutibilidade necessários para a análise pericial.

Para tarefas que exigem inferência analítica complexa, destaca-se a técnica de Cadeia de Raciocínio (*Chain of Thought* - CoT), proposta por Wei *et al.*. O método consiste em forçar a inteligência artificial a decompor um problema e verbalizar as etapas intermediárias de sua lógica antes de emitir o veredito final. No contexto da detecção de anomalias, a aplicação do CoT obriga o modelo a ponderar evidências cronológicas, cruzar perfis de usuários e justificar o desvio comportamental passo a passo, atuando como o motor para a geração de Inteligência Artificial Explicável (XAI).

3 TRABALHOS RELACIONADOS

Para situar a contribuição teórica e prática desta pesquisa, este capítulo apresenta uma revisão de trabalhos recentes publicados a partir de 2024. A seleção da literatura foi dividida em três eixos centrais que fundamentam a arquitetura proposta: o uso de Cadeia de Raciocínio (*Chain of Thought*) em Modelos de Linguagem de Larga Escala (LLMs), a aplicação de inteligência artificial na análise semântica de *logs*, e a integração da Inteligência Artificial Explicável (XAI) na segurança cibernética. O objetivo é demonstrar as lacunas existentes e como o *pipeline* cognitivo desenvolvido neste trabalho avança sobre as metodologias contemporâneas.

3.1 CADEIA DE RACIOCÍNIO (*CHAIN OF THOUGHT*) EM LLMS

A capacidade de raciocínio lógico em múltiplas etapas tornou-se o principal diferencial dos LLMs de nova geração, e a otimização da técnica de *Chain of Thought* (CoT) tem sido amplamente pesquisada para garantir respostas estruturadas e previsíveis.

Em um estudo recente, pesquisadores avaliaram a robustez do CoT frente a perturbações lógicas (LI et al., 2024). O trabalho introduziu uma classificação de falhas de raciocínio intermediário, demonstrando que forçar o modelo a verbalizar o passo a passo não apenas melhora a exatidão, mas permite que operadores humanos corrijam alucinações na raiz. O presente trabalho se apoia nesta premissa para justificar o uso do CoT como mecanismo de auditoria.

Além do texto livre, a técnica de CoT tem sido expandida para abordagens híbridas. Outro trabalho de destaque em 2024 propôs a integração de CoT com modelos de difusão de linguagem — sistemas de inteligência artificial que geram texto através da remoção progressiva de ruído — criando o conceito de *Diffusion-of-Thought* (DoT) (CHEN et al., 2024). O estudo demonstrou que dividir o raciocínio em etapas claras permite que modelos de menor escala computacional atinjam índices de precisão que antes eram exclusivos de LLMs massivos, validando a escolha arquitetural deste trabalho de utilizar um modelo otimizado (Gemma 2) em um ambiente com restrições de infraestrutura (GPU T4).

Ainda no mesmo ano, pesquisas sobre arquiteturas bimodais — prática de gerenciar duas formas separadas, porém coerentes, de entrega de TI: uma focada na estabilidade e previsibilidade, e a outra na agilidade e inovação — propuseram o *Multimodal-CoT* (ZHANG et al., 2024). Os autores desenvolveram um *framework* de duas etapas que separa explicitamente a "geração do raciocínio"da "inferência da resposta final". Essa fragmentação estrutural inspirou diretamente a metodologia de duas fases (*pipeline*) adotada neste TCC, onde a extração semântica e a classificação anômala ocorrem em estágios isolados.

3.2 ANÁLISE DE *LOGS* E DETECÇÃO DE ANOMALIAS

O processamento e a auditoria de *logs* em ambientes de segurança têm transitado do modelo de expressões regulares (Regex) para abordagens orientadas a contexto, alavancadas pelas capacidades sintáticas das LLMs.

Um abrangente estudo comparativo de *benchmark* conduzido em 2024 (WANG et al., 2024) avaliou modelos de linguagem contra abordagens tradicionais de detecção de anomalias em bases de dados de referência na literatura, como o HDFS (*Hadoop Distributed File System*) e o BGL (*Blue Gene/L*, focado em registros de supercomputadores). Os autores constataram que modelos baseados em instruções (*prompt-based LLMs*) superam metodologias que requerem treinamento supervisionado exaustivo, apresentando alta capacidade já em abordagens *zero-shot*. Esse achado serve como fundamentação teórica para a substituição de indexadores clássicos por inteligência artificial generativa neste trabalho. Contudo, a nossa arquitetura avança sobre essa premissa ao demonstrar que, para aplicações que exigem formatação estrutural rígida (como a geração de um repositório CSV), a abordagem *zero-shot* torna-se instável. Assim, a aplicação da técnica de *few-shot prompting* — consolidada na Fase 1 do nosso *pipeline* — demonstra ser uma evolução necessária para estabilizar a extração em cenários de alta entropia.

A substituição de indexadores clássicos foi reforçada por um levantamento acadêmico detalhado no *LLM4Log* (ZEYANG et al., 2024), que catalogou dezenas de implementações de análise de *logs* durante o ano. O documento enfatiza a adoção de técnicas de extração como o *few-shot prompting* para forçar a aderência tabular, eliminando a fragilidade estrutural das assinaturas convencionais diante de atualizações de sistemas operacionais.

Complementarmente, a literatura voltada para Operações de TI baseadas em Inteligência Artificial (AIOps) ressaltou a modelagem de fluxos de *logs* não estruturados como sequências de linguagem natural (LIU et al., 2024). O trabalho propôs que a leitura semântica do evento previne os alarmes falsos tipicamente gerados por ferramentas determinísticas (como o Logstash) quando novos formatos de *log* surgem inesperadamente, validando a abordagem semântica defendida na fundamentação teórica deste documento.

3.3 EXPLICABILIDADE (XAI) NA SEGURANÇA DA INFORMAÇÃO

A transparência algorítmica deixou de ser uma vantagem competitiva para se tornar um requisito operacional no combate à fadiga de alertas em Centros de Operações de Segurança (SOCs).

Em uma recente revisão da literatura (UDOFOT; OLUSEYI; BASSEY, 2024), destacou-se o papel da XAI na melhoria da transparência e confiança em Sistemas de Detecção de Intrusão (IDS). O estudo reforça que operadores humanos de cibersegurança tendem a ignorar alertas classificados com alta probabilidade numérica caso o modelo não forneça

as premissas lógicas de forma inteligível. Essa constatação teórica foi o motivador direto para a obrigatoriedade da saída formatada implementada na Fase 2 do presente TCC.

Da mesma forma, pesquisas como a de Islam *et al.* (2024) abordaram a redução da lacuna entre a complexidade do algoritmo e a confiança do usuário (ISLAM et al., 2024). Os autores demonstraram que sistemas assistidos por explicabilidade baseada em linguagem natural reduzem de uma forma significativa o Tempo Médio de Resposta (MTTR) em relação a painéis exclusivamente gráficos ou estatísticos.

Por fim, investigações sobre Ameaças Persistentes Avançadas (APT) mostraram que as ferramentas de XAI tradicionais *post-hoc*, como o SHAP (*SHapley Additive exPlanations*) e o LIME (*Local Interpretable Model-agnostic Explanations*), que utilizam cálculos matemáticos extras para tentar explicar as decisões de um modelo após ele já ter processado o dado, ainda sofrem com a opacidade da "caixa-preta"e exigem um processamento estatístico de alto custo computacional para detalhar as características do ataque (HASSAN et al., 2024). Em contraste a essas técnicas pesadas, o *pipeline* deste trabalho propõe o uso do próprio texto generativo via *Chain of Thought* para construir a narrativa pericial, garantindo que o veredito e a sua justificativa tática sejam gerados de forma unificada e direta.

3.4 RESUMO COMPARATIVO DOS TRABALHOS RELACIONADOS

A análise dos trabalhos relacionados evidencia os diferentes aspectos relacionados ao uso de LLMs em segurança e análise de *logs*. A proposta deste trabalho busca integrar essas diferentes perspectivas em uma única arquitetura, combinando uma etapa de triagem quantitativa com uma etapa de análise semântica baseada em LLM, complementada pela geração de justificativas em linguagem natural. As principais diferenças e comparações entre a proposta deste trabalho e os outros trabalhos existentes na literatura está apresentada na Tabela 1.

Tabela 1 – Principais características dos trabalhos relacionados e diferenças em relação à proposta.

Trabalho	**Foco principal**	**Diferença em relação à proposta**
(LI et al., 2024)	Robustez e falhas no raciocínio intermediário de LLMs utilizando CoT	Não aborda a aplicação do CoT na detecção de anomalias em *logs* de segurança.
(CHEN et al., 2024)	Uso de raciocínio estruturado em modelos de difusão de linguagem	Não considera a análise de *logs* nem a integração com mecanismos de detecção de anomalias.
(ZHANG et al., 2024)	Arquitetura em duas etapas para geração de raciocínio e inferência	Explora a divisão do processo de raciocínio, mas não direciona essa arquitetura para a análise de *logs* e detecção de ameaças.
(WANG et al., 2024)	Avaliação de LLMs para detecção de anomalias em bases de *logs*	Avalia o desempenho de LLMs, mas não propõe um *pipeline* híbrido em duas fases com análise explicável.
(ZEYANG et al., 2024)	Levantamento de técnicas baseadas em LLM para análise de *logs*	Apresenta uma visão abrangente das técnicas existentes, mas não implementa a arquitetura híbrida proposta neste trabalho.
(LIU et al., 2024)	Modelagem semântica de *logs* para detecção de anomalias em AIOps	Concentra-se na modelagem e detecção de anomalias, sem explorar a combinação entre triagem estatística e análise contextual por LLM.
(UDOFOT; OLUSEYI; BASSEY, 2024)	Aplicação de XAI em Sistemas de Detecção de Intrusão	Discute a importância da explicabilidade, mas não utiliza LLMs generativos para produzir justificativas contextuais a partir de *logs*.
(ISLAM et al., 2024)	Uso de explicações em linguagem natural em sistemas de segurança	Investiga os benefícios da explicabilidade, mas não propõe um *pipeline* específico para detecção de anomalias em *logs*.
(HASSAN et al., 2024)	Técnicas de XAI aplicadas à segurança cibernética	Analisa métodos tradicionais de explicabilidade, como SHAP e LIME, enquanto este trabalho utiliza a capacidade generativa do LLM para produzir justificativas.
Este trabalho	**Pipeline cognitivo híbrido para análise de *logs*, detecção de anomalias e geração de justificativas**	**Integra triagem estatística, análise semântica por LLM, CoT e XAI em uma arquitetura de duas fases, utilizando o Gemma 2.**

4 PROPOSTA ARQUITETURAL E EXPLICABILIDADE

Este capítulo detalha a concepção estrutural da solução proposta, descrevendo a integração entre modelos de linguagem de larga escala e fluxos de trabalho de segurança cibernética. A arquitetura foi desenhada sob o paradigma de *Pipeline Cognitivo*, onde a inteligência artificial não atua como um elemento isolado, mas como um orquestrador de transformações lógicas de dados. O modelo arquitetural apresentado é agnóstico em relação à ferramenta específica, exigindo fundamentalmente o uso de uma Inteligência Artificial com capacidades de processamento de linguagem natural e geração de explicabilidade (XAI).

4.1 PREMISSAS DE DESIGN E METODOLOGIA

O projeto fundamenta-se na utilização de um ***dataset*** como insumo fundamental. Academicamente, um *dataset* é definido como uma coleção estruturada de dados organizada para análise e processamento. No contexto desta pesquisa, ele compreende milhares de registros de eventos (*logs*) brutos, contendo tanto atividades rotineiras quanto simulacros de intrusões para validação da eficácia do sistema.

Para o processamento desses dados, optou-se pela técnica de ***Prompt Chaining*** (Encadeamento de *Prompts*). Esta técnica consiste em decompor uma tarefa complexa em várias etapas menores, onde a saída de uma chamada do modelo de linguagem serve como entrada (ou contexto) para a próxima. Ao segmentar o processo, reduz-se a carga cognitiva do modelo em cada etapa. Isso permite maior precisão e controle sobre o fluxo de informações, evitando que a IA sofra degradação de performance ao tentar realizar tarefas de formatação sintática e julgamento comportamental de forma simultânea.

4.2 COMPONENTES DETALHADOS DO SISTEMA

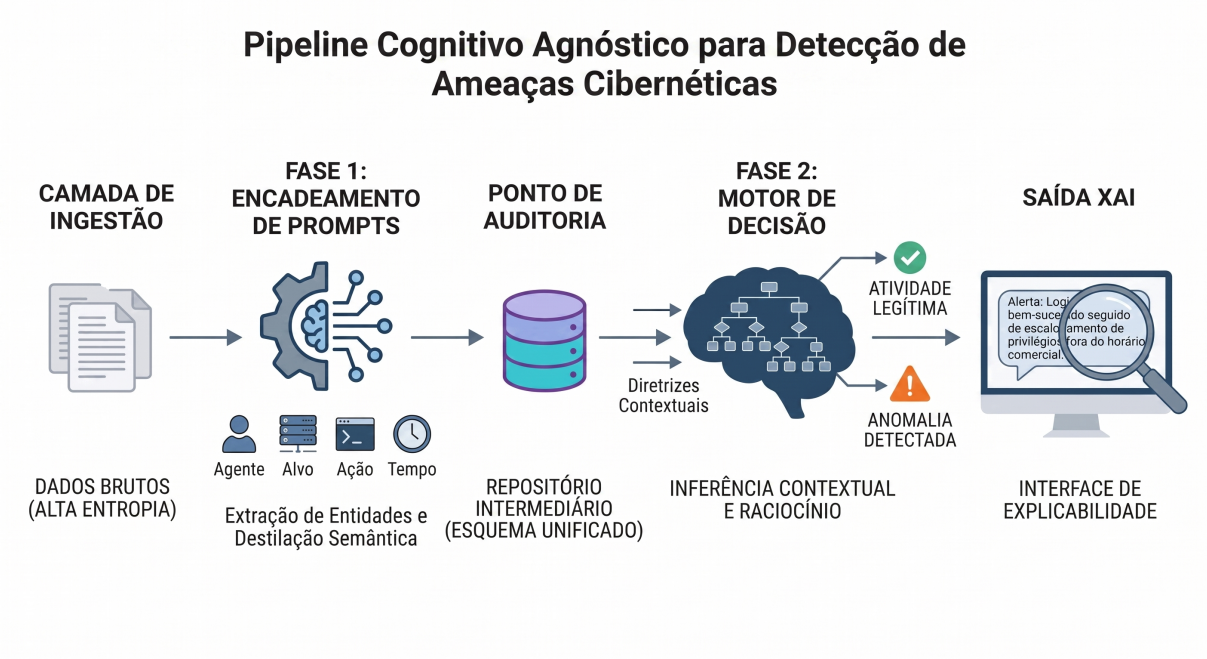
A arquitetura segmenta a atuação do Modelo de Linguagem de Larga Escala (LLM) em duas instâncias logicamente separadas por meio do *pipeline* descrito a seguir (figura 1).

A seguir, detalham-se os módulos que compõem o sistema e suas respectivas justificativas operacionais:

4.2.1 Base de Dados Bruta (Ingestão)

Este componente representa a camada de persistência inicial, mantendo a integridade dos dados originais. O dado nesta fase apresenta **alta entropia**, termo que na ciência da informação descreve o nível de desordem ou imprevisibilidade de um conjunto de dados. A

Figura 1 – Fluxo de dados e arquitetura conceitual do sistema de detecção baseado em IA.



Fonte: Elaborado pelo autor (2026).

heterogeneidade de fabricantes e sistemas operacionais faz com que não exista um padrão universal de registro; um evento de falha de autenticação em um sistema Linux possui estrutura textual completamente distinta do mesmo evento no Windows.

- **Entrada:** Arquivos de texto plano, *syslogs* ou registros de eventos não tratados, gerados em tempo real ou lidos de arquivos históricos.
- **Saída:** Fluxos de dados brutos e ruidosos encaminhados para a primeira camada de inteligência.

4.2.2 Módulo de Padronização e Estruturação (LLM - Fase 1)

Nesta fase inicial, o modelo de linguagem é especializado na função de ***Entity Extraction*** (Extração de Entidades), um processo fundamental para transformar registros amorfos em variáveis computáveis e correlacionáveis. Para que o sistema consiga estruturar os dados, a classificação automática conduzida pela inteligência artificial concentra-se em isolar os seguintes elementos-chave:

- **Agente da Ação:** O usuário, processo ou IP de origem, respondendo diretamente a "quem"iniciou o evento;
- **Alvo:** O arquivo, porta ou serviço afetado, indicando qual é o objetivo da ação;

- **Carimbo de Tempo (*timestamp*):** O marcador temporal vital para a ordenação cronológica estrita dos acontecimentos;
- **Ação/Comando:** O registro de execução que denota a intenção técnica do agente.

A extração exata dessas quatro entidades é o que viabiliza a detecção de anomalias comportamentais complexas — como as movimentações laterais —, pois fornece a base estrutural necessária para que o sistema rastreie a transição contínua de um mesmo ofensor por diferentes alvos ao longo da linha do tempo.

4.2.2.1 Repositório Intermediário de *Logs* Processados

Área de armazenamento temporário que guarda o dado já estruturado em formatos unificados (como JSON ou csv). Este componente é uma salvaguarda arquitetural para a auditabilidade. Em sistemas baseados em inteligência artificial generativa, existe o risco inerente de alucinação (geração de dados incorretos). O repositório atua como um *checkpoint* de integridade: se a fase de decisão emitir um falso positivo, o analista de segurança pode consultar este repositório para verificar se o erro ocorreu por uma falha de raciocínio lógico da segunda instância da IA ou por uma extração sintática incorreta realizada pela primeira.

4.2.3 Módulo de Triagem Quantitativa (Filtro Algorítmico)

Entre a fase de estruturação sintática e a inferência cognitiva final, a arquitetura introduz uma camada de roteamento baseada em algoritmos determinísticos clássicos. Uma vez que os dados estão estruturados no repositório intermediário (com colunas bem definidas, como IP de Origem e Usuário), este módulo utiliza bibliotecas de manipulação de dados (como o *Pandas* em ambiente Python) para aplicar Análises Estatísticas de Frequência e Tabelas de Dispersão (*Hash Maps*).

A justificativa arquitetural para a inclusão deste componente é ligada às limitações de hardware e ao fenômeno de colapso de contexto (*lost in the middle*) enfrentado por Modelos de Linguagem. Submeter centenas ou milhares de linhas de *log* simultaneamente ao Motor de Inferência (Fase 2) saturaria a janela de contexto da inteligência artificial e consumiria recursos excessivos de Memória de Vídeo (VRAM).

Portanto, este módulo atua como um mecanismo de redução de escopo. Ele quantifica as ocorrências, identifica os ofensores estatísticos mais ruidosos da rede e recorta a linha do tempo estritamente vinculada a esses alvos. É este subconjunto isolado e concentrado de informações que será efetivamente encaminhado para a próxima fase do *pipeline*.

4.2.4 Motor de Inferência e Decisão (LLM - Fase 2)

Este é o núcleo analítico do sistema, onde o modelo de linguagem exerce plenamente sua capacidade de *reasoning* (raciocínio lógico). Em vez de formatar texto, a IA atua como um motor de regras dinâmicas e contextuais. Ela recebe o dado estruturado e o confronta com diretrizes comportamentais preestabelecidas.

Para garantir que esse processamento seja validável e transparente, um dos requisitos fundamentais deste motor de inferência é a geração de Cadeias de Raciocínio (*Chain of Thought* - CoT). A técnica de CoT obriga a inteligência artificial a externalizar, passo a passo, a lógica utilizada para correlacionar os eventos antes de emitir o seu veredito final. A adoção desta abordagem arquitetural justifica-se por dois motivos críticos: primeiramente, o processamento sequencial induzido pelo CoT eleva a precisão analítica do modelo, mitigando alucinações em tarefas de alta complexidade; em segundo lugar, a trilha de raciocínio gerada torna-se o artefato bruto indispensável para a construção da explicabilidade, permitindo que as decisões da IA sejam auditáveis.

A importância deste componente reside na superioridade da avaliação conjunta de variáveis. Diferente de um IDS tradicional baseado em limites estáticos (que bloquearia um IP simplesmente após cinco tentativas falhas de *login*), a capacidade cognitiva permite que a IA pondere o contexto. O modelo é capaz de inferir que múltiplas tentativas falhas, seguidas imediatamente por um acesso bem-sucedido e pela execução de comandos de escalonamento de privilégio fora do horário comercial, configuram de fato um ataque de força bruta bem-sucedido, e não um mero esquecimento de senha.

- **Entrada:** O *log* padronizado extraído do repositório intermediário e um contexto referencial (ex: perfis de horários de acesso e regras de negócio).
- **Saída:** Um veredito binário formal (Anômalo vs. Legítimo) acoplado a uma justificativa lógica construtiva (*Chain of Thought*).

4.2.5 Painel de Resultados e Explicabilidade (XAI)

Este componente final materializa o conceito de ***Explainable AI*** (Inteligência Artificial Explicável - XAI), referindo-se aos métodos que tornam os processos decisórios das IAs compreensíveis e transparentes para operadores humanos.

Enquanto algoritmos tradicionais de *Machine Learning* operam como "caixas-pretas", entregando apenas um limiar de probabilidade numérico, o painel XAI deste sistema exige a construção de uma narrativa lógica com base na Cadeia de Raciocínio (CoT) gerada pela fase anterior. Para que a explicabilidade seja efetiva, a saída do painel deve correlacionar explicitamente a anomalia detectada no Motor de Inferência com as entidades extraídas no Módulo de Padronização. Ao detalhar as evidências técnicas em linguagem natural, reduz-se o tempo médio de resposta (*Mean Time to Respond* - MTTR) da equipe de resposta a

incidentes. Essa transparência ataca diretamente a ***alert fatigue*** (fadiga de alertas) — a dessensibilização dos analistas causada por um volume massivo de notificações desprovidas de contexto.

4.3 FLUXO DE DADOS E TRANSFORMAÇÃO

O fluxo de informações desenhado segue o princípio do afunilamento semântico e estatístico de dados. O registro inicia sua jornada como uma sequência de caracteres de alta entropia, passa por um filtro cognitivo de destilação das entidades essenciais (Fase 1) e é armazenado de forma estruturada. Em seguida, atravessa uma triagem volumétrica algorítmica para isolar os maiores ofensores, contornando limitações de processamento de hardware. Por fim, o subconjunto crítico é submetido ao julgamento comportamental do LLM (Fase 2), terminando sua jornada como uma sentença interpretativa de alto valor estratégico.

Essa transformação progressiva e híbrida garante que o alto custo computacional da inteligência artificial seja empregado apenas onde é estritamente necessário, e que a intervenção do operador humano seja requisitada apenas no estágio final, após a IA ter mitigado a assimetria informacional e fundamentado as evidências forenses de forma autônoma.

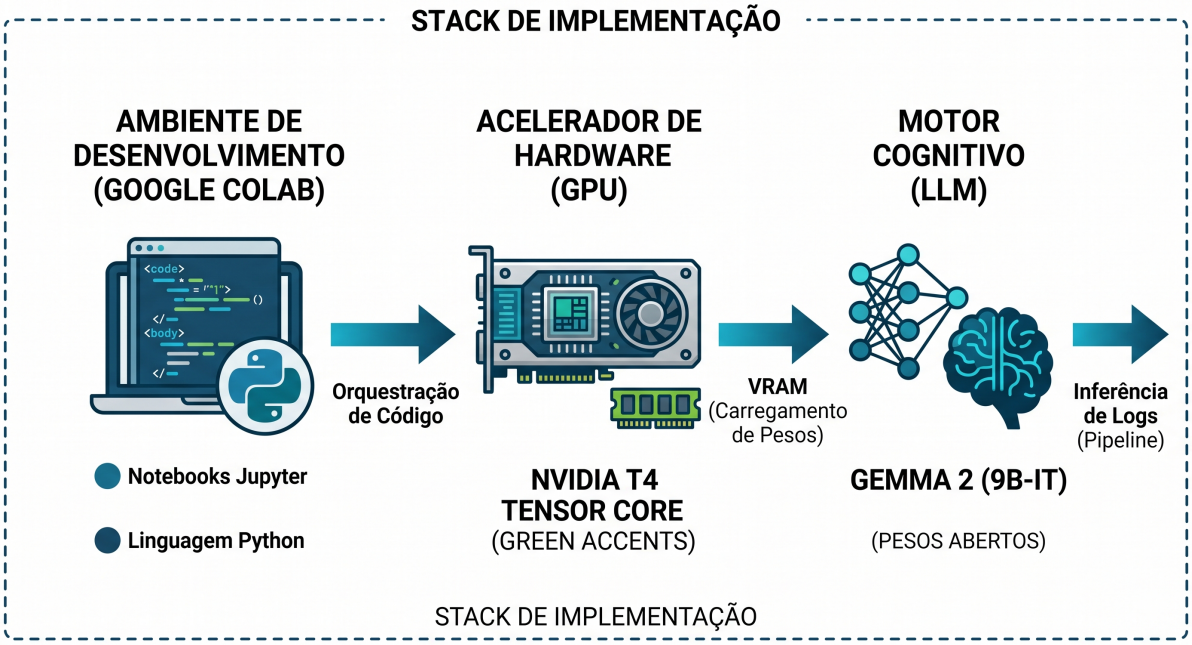
5 METODOLOGIA DE IMPLEMENTAÇÃO E AMBIENTE EXPERIMENTAL

Este capítulo documenta a instanciação prática da arquitetura proposta no Capítulo 4, detalhando as ferramentas, o ambiente de execução e as configurações paramétricas adotadas para validar o *pipeline* cognitivo. O objetivo primário desta seção é fornecer o rigor descritivo necessário para garantir a reprodutibilidade do experimento. A implementação metodológica está dividida na configuração do ambiente de *hardware* e *software*, na inicialização do modelo de linguagem e, subsequentemente, na execução estruturada das fases de estruturação de *logs* e inferência comportamental.

5.1 AMBIENTE DE DESENVOLVIMENTO E *HARDWARE*

Para viabilizar a execução do modelo de linguagem de larga escala mitigando a necessidade de infraestrutura local de altíssimo custo, o sistema foi integralmente implementado e orquestrado no ambiente *Google Colaboratory* (Colab). Trata-se de um ambiente de *notebooks* Jupyter hospedado em nuvem, que padroniza as dependências de *software* e facilita a execução de rotinas em linguagem Python.

Figura 2 – Stack de implementação do ambiente experimental utilizando Google Colab e GPU NVIDIA T4.



Fonte: Elaborado pelo autor (2026).

O fator crítico para a adoção desta plataforma foi a viabilidade de transição do ambiente de execução padrão para aceleradores de *hardware* dedicados. A operação do projeto

foi preparada utilizando Unidades de Processamento Gráfico (GPUs) NVIDIA T4 *Tensor Core*. A alocação da GPU T4 configura-se como um requisito arquitetural fundamental, visto que a inferência de LLMs demanda alta capacidade de processamento paralelo e VRAM (memória de vídeo) para o carregamento dos pesos e tensores do modelo. A utilização da computação acelerada por GPU permitiu uma redução na latência durante a ingestão do *dataset* de *logs*, garantindo que a inteligência artificial operasse com o rendimento exigido por um cenário de monitoramento de segurança contínuo.

5.2 SELEÇÃO DO MODELO: GEMMA 2

O motor cognitivo central selecionado para operar ambas as fases do *pipeline* (Padronização e Decisão) foi o modelo de pesos abertos Gemma 2. A escolha por este modelo específico justifica-se por dois fatores técnicos primordiais: o balanceamento entre eficiência computacional e a sua capacidade avançada de raciocínio.

Primeiramente, a família Gemma compartilha componentes técnicos fundamentais com os modelos proprietários da linha Gemini, entregando um desempenho de estado da arte em uma arquitetura leve o suficiente para ser instanciada de forma otimizada em *hardwares* de acesso comercial, como a GPU T4 referida.

Em segundo lugar, a arquitetura Gemma 2 possui um treinamento voltado para o alinhamento de instruções complexas e para a geração de Cadeias de Raciocínio (*Chain of Thought* - CoT). No escopo deste trabalho, essa característica atua como um mecanismo de **Explicabilidade (XAI) nativa**. Em vez de implementar uma arquitetura satélite de XAI — que exigiria o treinamento de um modelo secundário apenas para decifrar as decisões do classificador principal, aumentando consideravelmente o custo computacional e o esforço de engenharia — o projeto explora a habilidade da Gemma 2 de articular suas premissas lógicas de forma autônoma e inerente à sua resposta.

Em termos de implementação, o modelo foi instanciado para atuar em duas frentes isoladas: primeiro, processando as sequências brutas para a extração de entidades e consolidação de um *log* intermediário estruturado; em seguida, operando sobre este repositório legível para consultar assinaturas comportamentais, determinar a presença de anomalias e emitir a justificativa textual em uma única iteração de inferência.

5.3 INGESTÃO DE DADOS E MODELAGEM DE CONTEXTO COMPORTAMENTAL

Para fundamentar a avaliação empírica do sistema, a metodologia estabelece a utilização de um *dataset* contendo registros de acesso sistêmico, tais como *logs* de autenticação SSH provenientes de sistemas operacionais Linux. A partir desta base de dados histórica, o sistema extrai as métricas necessárias para modelar o perfil comportamental de referência de cada usuário monitorado. Este perfil engloba variáveis intrínsecas à operação diária,

incluindo a localização geográfica habitual, o bloco de endereços IP comumente utilizados, as janelas de horários de trabalho padrão e os comandos administrativos rotineiros.

Esta modelagem de contexto é a premissa técnica para que o sistema abandone as abordagens de regras estáticas. Ao fornecer à inteligência artificial não apenas o evento suspeito isolado, mas também o histórico recente de operações e o perfil esperado do agente, a ferramenta adquire o insumo necessário para discernimento. Esse contexto permite ao sistema distinguir um acesso atípico legítimo (como manutenções programadas fora do horário comercial) de uma anomalia maliciosa, caracterizando assim a inferência baseada em comportamento.

Para garantir o controle preciso sobre as variáveis de teste e mitigar a dependência de bases de dados sintéticas puramente acadêmicas, o *dataset* utilizado neste trabalho foi gerado por meio de um ambiente de simulação próprio. Instanciou-se um servidor Linux em uma arquitetura isolada via contêineres Docker, configurado para registrar eventos reais de autenticação e execução de processos. Esta abordagem gerou um repositório composto por 421 registros sob alta entropia, contendo tanto o ruído estrutural característico de um ambiente de produção real quanto vetores de ataque explicitamente simulados (como força bruta e varreduras de rede), fornecendo o insumo empírico ideal para avaliar o motor cognitivo.

O código-fonte completo da solução desenvolvida, incluindo os scripts de orquestração em Python, o Dockerfile do ambiente simulado e os notebooks de experimentação, encontra-se disponível publicamente em repositório remoto (SILVA; BACELAR, 2026).

5.4 EXECUÇÃO DA FASE 1: DESTILAÇÃO SEMÂNTICA E ESTRUTURAÇÃO

A primeira etapa do *pipeline* cognitivo foca estritamente na conversão do dado ruidoso. Por meio de instruções no código, um *prompt* sistêmico direciona o modelo Gemma 2 a atuar exclusivamente na extração de entidades técnicas.

Em modelos de linguagem de larga escala, o comportamento da geração de texto é regulado por hiperparâmetros, sendo a "temperatura"(*temperature*) um dos mais críticos. Este parâmetro controla o grau de aleatoriedade e previsibilidade das respostas da inteligência artificial. Valores altos permitem que o modelo seja mais criativo e gere respostas variadas, enquanto valores próximos a zero tornam o modelo estritamente determinístico, literal e conservador.

Para garantir a integridade da análise de segurança e inibir alucinações textuais — fenômeno onde a IA inventa dados inexistentes — o modelo foi parametrizado nesta fase com uma temperatura de inferência extremamente baixa (0.1). Essa configuração força a IA a realizar uma leitura rigorosa do *log* e a produzir uma saída previsível, sem margem para interpretações criativas indesejadas.

A instrução da Fase 1 solicita que a inteligência ignore metadados secundários (como

identificadores de processo - PID) e extraia os quatro eixos essenciais da informação: temporalidade (data e turno), rede (IP de origem e inferência geográfica), usuário e resumo da ação. Como resultado empírico, uma entrada desestruturada de sistema é traduzida pelo modelo para uma *string* simplificada e delimitada, assemelhando-se a um formato de valores separados por vírgula (CSV). Essa etapa de padronização atua como um filtro de redução de dimensionalidade, entregando um artefato semântico limpo para o motor de decisão.

Além da restrição paramétrica de temperatura, a implementação prática desta fase exigiu o refinamento da técnica de engenharia de *prompt*. Testes preliminares conduzidos sob a abordagem *zero-shot* (submissão de diretrizes sem exemplos prévios) resultaram em uma severa degradação da formatação estrutural, com o modelo confundindo os delimitadores textuais e alternando o alinhamento das entidades essenciais. Para sanar este gargalo de estruturação, o sistema foi parametrizado com a técnica de *few-shot prompting*. Ao injetar um exemplo estrito de entrada bruta e sua respectiva saída esperada diretamente no *chat template* do modelo, forçou-se a inteligência artificial a mimetizar o padrão exato de extração, garantindo a conversão determinística do texto livre para o formato de colunas tabulares.

Por fim, uma decisão arquitetural para a viabilidade e estabilidade desta fase foi a adoção do processamento em lotes (*batch processing*). Devido às restrições físicas de janela de contexto e ao limite máximo de geração de *tokens* inerentes aos LLMs, a submissão do arquivo de *log* completo em uma única requisição resultaria no truncamento prematuro da resposta ou na degradação da atenção do modelo — um fenômeno documentado na literatura como *lost in the middle*, que eleva drasticamente as taxas de alucinação estrutural. Para contornar essa limitação, o algoritmo foi projetado para particionar o *dataset* bruto em blocos menores (lotes de 20 a 25 linhas), submetendo-os sequencialmente ao motor de inferência. Ao término do ciclo iterativo, as saídas parciais foram concatenadas programaticamente, consolidando o repositório CSV final. Essa estratégia garantiu a manutenção estrita do padrão imposto pelo *few-shot prompting* durante toda a execução, otimizando o consumo de memória de vídeo (VRAM) e garantindo a extração integral dos dados.

5.5 EXECUÇÃO DA FASE 2: INFERÊNCIA CONTEXTUAL E EXPLICABILIDADE (XAI)

A segunda etapa do *pipeline* consome o *log* estruturado gerado pela fase antecedente. Para garantir a eficiência computacional, a implementação adotou uma abordagem de triagem híbrida antes de acionar a inteligência artificial. Utilizando a biblioteca *Pandas*, aplicou-se um algoritmo de Análise Estatística Descritiva de Frequência por meio de Tabelas de Dispersão (*Hash Maps*). Esse mecanismo contabiliza volumetricamente as

ocorrências no *dataset*, atuando como um filtro quantitativo para isolar apenas os atores mais ruidosos da rede — como um endereço IP externo agressivo ou um usuário interno suspeito.

Após essa redução algorítmica de escopo, o histórico isolado da entidade selecionada é submetido à instância do modelo Gemma 2. A requisição é acompanhada de um *prompt* focado em raciocínio, instruindo a IA a simular as heurísticas de um analista sênior de Centro de Operações de Segurança (SOC). A partir da análise desta janela cronológica, o motor cognitivo executa a etapa de inferência. É importante destacar que o classificador não possui viés de alarme constante; dependendo da congruência semântica e comportamental dos eventos em sequência, o *pipeline* possui a restrição diretiva de emitir um veredito final categorizando o acesso estritamente como LEGÍTIMO ou ANÔMALO.

Para acomodar essa transição de uma tarefa de extração de dados (Fase 1) para uma tarefa de articulação lógica, o parâmetro de temperatura do modelo foi levemente ajustado. A inferência na Fase 2 operou com uma temperatura de 0.2. Esse leve incremento em relação à primeira fase permite que a inteligência artificial mantenha o rigor analítico, mas ganhe a flexibilidade linguística necessária para redigir textos analíticos mais fluidos e articulados.

Por fim, para mitigar o dilema da "caixa-preta", o *pipeline* exige que o modelo forneça, de forma automatizada, a cadeia de raciocínio utilizada. A saída do código é forçada a formatar a resposta técnica separando as "Evidências Observadas"da sua "Cadeia de Raciocínio"(*Chain of Thought*). Em cenários de ameaça, o modelo não apenas aponta o risco, mas explica pedagogicamente o vetor do ataque — detalhando, por exemplo, como o uso encadeado de comandos de terminais interativos e ferramentas de varredura (como o Nmap) caracteriza uma fase de reconhecimento de rede e movimentação lateral. Essa etapa encerra o fluxo do sistema consolidando a entrega de Inteligência Artificial Explicável (XAI), onde o artefato gerado detém a profundidade necessária para guiar a resposta a incidentes do administrador da infraestrutura.

6 RESULTADOS E DISCUSSÕES

Este capítulo apresenta os resultados empíricos obtidos a partir da execução do *pipeline* cognitivo proposto, submetendo o ecossistema de detecção aos eventos gerados no ambiente de simulação detalhado no Capítulo 5. A avaliação da arquitetura é dividida na validação da estruturação de dados (Fase 1) e na eficácia do motor de inferência comportamental acoplado à geração de explicabilidade (Fase 2). Ao final, promove-se uma discussão crítica sobre o desempenho da solução e seus custos computacionais associados.

6.1 EFICÁCIA DA DESTILAÇÃO SEMÂNTICA (FASE 1)

Nesta etapa inicial do *pipeline*, o conceito de eficácia é definido estritamente pela capacidade do modelo de gerar uma saída que corresponda com exatidão ao formato estruturado que foi planejado no capítulo anterior. A validação consistiu em submeter o *dataset* bruto, caracterizado por alta entropia estrutural e composto por 421 registros do serviço SSH, à camada de normalização da Gemma 2. O objetivo era atestar se a parametrização restritiva e a engenharia de *prompt* seriam capazes de atuar como um redutor de dimensionalidade efetivo, forçando os dados a saírem exatamente na estrutura esperada pela arquitetura, dispensando de forma segura o uso de Expressões Regulares (Regex).

O Quadro 1 ilustra o resultado comparativo da transformação aplicada a um recorte aleatório de conexões do arquivo gerado pelo servidor simulado, evidenciando o alinhamento da saída real com o escopo planejado.

A análise do artefato gerado demonstra a eficácia da destilação semântica. O modelo isolou as entidades de rede (IP e Usuário) em colunas distintas, expurgou metadados desnecessários para a análise comportamental (como o *PID sshd* e a porta efêmera) e inferiu corretamente o turno ("Noite") baseado no carimbo de tempo. A exclusão das portas efêmeras é uma decisão estratégica de redução de ruído, visto que são alocações numéricas aleatórias do sistema operacional que não refletem o ataque. Em contrapartida, o sistema preservou intactos os comandos subjacentes (como, por exemplo, `COMMAND=/bin/bash`). A retenção dessas cargas úteis (*payloads*) é crucial para a Fase 2, pois, diferentemente das portas, os comandos revelam a intenção pós-autenticação do usuário. Isso garante que o motor cognitivo receba o contexto exato para identificar atividades de exploração ou controle do sistema durante a avaliação comportamental.

Quadro 1 – Comparativo empírico entre o log bruto e o repositório estruturado gerado pela IA.

```
--- ANTES: Log Bruto de Alta Entropia ---
Jun 05 22:53:02 honeypot-server sshd[1024]: Failed password for root from
195.241.151.7 port 52244 ssh2
Jun 05 22:53:04 honeypot-server sshd[1024]: Accepted password for admin_tcc
from 187.12.5.42 port 52256 ssh2 COMMAND=/bin/bash
Jun 05 22:53:05 honeypot-server sshd[1024]: Connection closed by 10.0.0.5
port 52256

--- DEPOIS: Repositório Intermediário Limpo (CSV) ---
DataHora,Turno,IP_Origem,Usuario,Acao_Resumo
Jun 05 22:53:02,Noite,195.241.151.7,root,Falha de senha (ssh2)
Jun 05 22:53:04,Noite,187.12.5.42,admin_tcc,Login com sucesso (ssh2)
COMMAND=/bin/bash
Jun 05 22:53:05,Noite,10.0.0.5,,Fechamento de conexão
```

Fonte: Elaborado pelo autor (2026).

6.2 AVALIAÇÃO DO MOTOR DE INFERÊNCIA E EXPLICABILIDADE

Após a estruturação dos registros na Fase 1, o Motor de Inferência foi executado com o intuito de aplicar a nova abordagem proposta e avaliar a sua capacidade de compreensão de contexto. Simulando a carga cognitiva de um analista humano, o foco desta avaliação recai sobre observar como a ferramenta interpreta os dados e formula os seus vereditos. Para examinar o comportamento do modelo na prática, a inteligência artificial foi submetida a cenários de ataque que exigem diferentes níveis de percepção.

6.2.1 Cenário A: Detecção de Força Bruta Externa

No primeiro cenário, o motor foi alimentado com a janela temporal correspondente ao endereço IP `195.241.151.7`. Este cenário visou atestar o reconhecimento de ataques de força bruta. Essa tática se caracteriza pelo uso de processos automatizados para testar exaustivamente combinações de credenciais, deixando como rastro comportamental uma alta concentração de falhas de autenticação consecutivas originadas de uma mesma fonte em um curto intervalo temporal. A saída gerada pelo painel de Inteligência Artificial Explicável (XAI) analisando esse comportamento está reproduzida no Quadro 2.

A Cadeia de Raciocínio (*Chain of Thought*) externalizada pelo modelo atendeu plenamente aos requisitos de explicabilidade que exigimos. A IA detectou o evento como anômalo e sequenciou a fundamentação lógica mapeando o fator temporal, o vetor de ataque (SSH) e a criticidade do alvo (*root*), entregando um artefato pronto para auditoria humana.

Quadro 2 – Saída gerada pelo Painel de Explicabilidade para o Cenário A.

```
ALVO SOB ANÁLISE: 195.241.151.7

**Evidências Observadas:** O IP 195.241.151.7 tentou realizar múltiplas
conexões SSH com o usuário "root" entre 22:53 e 22:56. Todas as conexões
resultaram em falhas de senha.

**Cadeia de Raciocínio (CoT):
** 1. **Falhas de senha em sequência:** O registro de múltiplas
falhas de senha em um curto período de tempo é um padrão de
comportamento suspeito. Ataques de força bruta, onde um atacante
tenta adivinhar senhas, frequentemente resultam em várias tentativas
falhas em rápida sucessão.
2. **Usuário "root":** O usuário "root" possui privilégios de
administrador no sistema, o que significa que um sucesso nesse ataque
poderia dar ao atacante controle total do sistema.
3. **Conexões SSH:** O protocolo SSH é frequentemente usado para acesso
remoto a servidores, tornando-o um alvo comum para ataques.

**Veredito Final:** ANÔMALO
```

Fonte: Elaborado pelo autor (2026).

6.2.2 Cenário B: Ameaça Interna e Reconhecimento

O segundo cenário representou um desafio heurístico mais complexo, focado no comportamento do usuário `admin_tcc`. No escopo da cibersegurança, uma ameaça interna (*insider threat*) ocorre quando ações maliciosas são conduzidas sob o manto de um acesso aparentemente autorizado — seja por um colaborador mal-intencionado ou por um atacante externo que conseguiu comprometer credenciais válidas.

Diferente do Cenário A, as credenciais inseridas neste caso estavam corretas, o que faria este acesso transpassar barreiras de autenticação tradicionais sem gerar alertas críticos. Consequentemente, o julgamento da anomalia dependia inteiramente da avaliação comportamental das ações *pós-login*. O resultado analítico e a fundamentação da solução diante deste desafio são apresentados no Quadro 3.

A análise do Cenário B apresenta uma outra face de nosso sistema. A inteligência artificial demonstrou a capacidade de correlacionar comandos horizontalmente ao longo da linha do tempo, inferindo que a conjunção de um terminal interativo com varreduras de rede (*nmap*) indica uma fase de reconhecimento de infraestrutura (*network scanning*) ou movimentação lateral, sinalizando uma provável presença de um ator malicioso sob posse de credenciais válidas.

Quadro 3 – Saída gerada pelo Painel de Explicabilidade para o Cenário B.

```
ALVO SOB ANÁLISE: Usuário admin_tcc

**Evidências Observadas:** O usuário admin_tcc realizou múltiplos logins
via SSH em um curto período de tempo (menos de 10 minutos). Após o
primeiro login, executou um comando ‘nmap‘ para escanear portas em uma
rede local (192.168.1.0/24). Em seguida, executou repetidamente o
comando ‘/bin/bash‘, indicando acesso a um shell. Após mais alguns
acessos, o usuário executou novamente o comando ‘nmap‘ para escanear portas.

**Cadeia de Raciocínio (CoT):
** 1. **Múltiplos Logins:** A frequência de logins em um curto
período de tempo pode indicar uma tentativa de exploração
de vulnerabilidades.
2. **Escaneio de Rede (Nmap):** O uso do comando ‘nmap‘ para escanear
portas em uma rede local é uma ação comum em testes de segurança,
mas também pode ser usada por atacantes para identificar sistemas
vulneráveis e serviços.
3. **Acesso a Shell:** O acesso repetido a um shell (‘/bin/bash‘) permite
ao usuário executar qualquer comando no sistema, o que aumenta o potencial
de danos se o usuário for mal-intencionado.

Considerando a combinação desses fatores, o comportamento do usuário é
suspeito e pode indicar uma atividade maliciosa.

**Veredito Final:** ANÔMALO
```

Fonte: Elaborado pelo autor (2026).

6.2.3 Cenário C: Triagem Quantitativa Algorítmica e Perfilamento Qualitativo

Para validar a arquitetura contra um fluxo de dados de maior escala e com marcações temporais realistas, o ecossistema foi submetido ao processamento integral do *dataset* simulado, composto por 421 registros históricos. Em ambientes operacionais de Centros de Operações de Segurança (SOC), a volumetria inviabiliza o envio imediato de todas as linhas brutas para modelos de linguagem. Como discutido no capítulo anterior, submeter uma carga excessiva de informações em uma única requisição satura a janela de contexto do LLM, provocando a degradação da atenção do modelo (fenômeno conhecido como *lost in the middle*). Isso eleva drasticamente o risco de alucinações e a perda de informações críticas durante o raciocínio lógico. Desse modo, a arquitetura aplica um modelo híbrido dividido em duas etapas: uma triagem puramente quantitativa por meio de programação convencional, seguida de uma análise qualitativa conduzida pelo modelo Gemma 2.

6.2.3.1 Etapa Quantitativa: Triagem por Análise de Frequência

Na primeira etapa, aplicou-se um algoritmo de Análise Estatística Descritiva de Frequência, estruturado por meio de Tabelas de Dispersão (*Hash Maps*) nativas da biblioteca *Pandas* em ambiente Python. Este mecanismo realizou a contagem volumétrica agregada de ocorrências por chaves de rede (`IP_Origem`) e credenciais (`Usuario`) em milissegundos. A seleção dessas chaves específicas fundamenta-se na taxonomia das ameaças cibernéticas: o agrupamento por endereço IP mapeia ofensores externos ruidosos (como ataques de força bruta), enquanto o agrupamento por credencial rastreia anomalias de ameaças internas (usuários logados com comportamento atípico). Essa estratégia permite separar o tráfego legítimo do ruído anômalo, fornecendo à inteligência artificial uma linha do tempo isolada e contextualizada para cada entidade analisada.

O objetivo desta etapa quantitativa foi atuar como uma técnica de priorização e redução de escopo, isolando os maiores ofensores estatísticos do sistema antes do acionamento da inteligência artificial. O cálculo identificou que, das 421 linhas totais, um pequeno grupo de atores concentrava a quase totalidade das interações na infraestrutura. O Quadro 4 apresenta os resultados numéricos exatos obtidos por esta filtragem algorítmica.

Quadro 4 – Resultado quantitativo da triagem volumétrica por tabelas de dispersão.

Entidade Identificada	Tipo de Ativo	Total de Logs	Representatividade
IP 10.0.0.5	Origem Externa	180 registros	42,75% do dataset
IP 95.161.22.128	Origem Externa	67 registros	15,91% do dataset
IP 45.250.247.54	Origem Externa	56 registros	13,30% do dataset
Usuário admin_tcc	Conta Interna	55 registros	13,06% do dataset

Fonte: Elaborado pelo autor (2026).

A análise dos dados consolidados no Quadro 4 revela que as quatro entidades identificadas acumulam, somadas, 358 registros, o que representa aproximadamente 85% do volume total do *dataset*. Essa detecção estatística mostra que uma parcela mínima de atores na infraestrutura gerou a maioria do tráfego ruidoso do sistema.

Na prática, esses resultados indicam que o analista de segurança não precisa submeter o arquivo completo à inteligência artificial. Com essa informação quantitativa em mãos, a arquitetura realiza a extração das linhas do tempo pertencentes estritamente a esses quatro alvos. Esse subconjunto concentrado e isolado é o que constituirá o insumo contextual enviado para a etapa qualitativa subsequente. Desse modo, o sistema economiza memória de vídeo (VRAM) e tempo de processamento da GPU, permitindo que o modelo Gemma 2 foque sua capacidade analítica apenas nos comportamentos de alto impacto operacional.

6.2.3.2 Etapa Qualitativa: Perfilamento Contextual via LLM

Uma vez concluída a filtragem quantitativa, os dados estatísticos brutos do Quadro 4 foram convertidos em amostras contextuais isoladas e encaminhados para o motor de inferência. A inteligência artificial teve como objetivo a avaliação semântica das sequências para classificar a intenção do alvo com base na *Cyber Kill Chain*.

O Quadro 5 exibe os resultados e as justificativas técnicas geradas de forma automatizada pelo modelo para os alvos triados.

Quadro 5 – Perfilamento qualitativo das ameaças ativas identificadas.

```
ALVO: IP 95.161.22.128 (Ameaça Crítica)
Tática Mapeada: Reconhecimento, Exploração e Execução
Veredito Qualitativo: Comportamento de altíssimo risco. O modelo
identificou um padrão persistente de força bruta para quebra de
autenticação seguido por um acesso bem-sucedido focado na leitura
do arquivo /etc/shadow, indicando o comprometimento direto de
credenciais criptografadas do sistema operacional.

ALVO: IP 45.250.247.54 (Ataque Automatizado)
Tática Mapeada: Reconhecimento e Força Bruta
Veredito Qualitativo: Padrão típico de varredura ativa
direcionada ao usuário "root". A constância e a velocidade
das tentativas falhas sugerem a operação de ferramentas
robotizadas de dicionário de senhas.

ALVO: Usuário admin_tcc (Ameaça Interna)
Tática Mapeada: Reconhecimento e Exploração
Veredito Qualitativo: Comportamento altamente suspeito.
A utilização da conta para disparar comandos "nmap"
contra o segmento local (192.168.1.0/24) associada à
abertura de terminais interativos "bash" sinaliza táticas
de mapeamento de ativos internos e preparação para
movimentação lateral.

ALVO: IP 10.0.0.5 (Comportamento Anômalo)
Tática Mapeada: Reconhecimento
Veredito Qualitativo: Ciclo contínuo de abertura e fechamento
imediato de conexões. A ausência de payloads de ataque sugere
a execução de rotinas automatizadas de scripts de monitoramento
de disponibilidade ou checagem de portas abertas.
```

Fonte: Elaborado pelo autor (2026).

A estruturação em duas etapas demonstra, na prática, o sucesso da associação entre a eficiência computacional da filtragem algorítmica e a capacidade de reconstrução forense do LLM. Essa abordagem mostra que é viável realizar uma pré-análise quantitativa para

reduzir o volume massivo de informações operacionais e, em seguida, submeter apenas os recortes críticos ao modelo Gemma 2, obtendo laudos analíticos acionáveis.

Enquanto o algoritmo descritivo foca estritamente em quantificar o volume das interações, o julgamento qualitativo da Gemma 2 decodifica a gravidade e a intenção por trás dessas ações. Essa sinergia arquitetural evidencia o valor prático da proposta, visto que permitiria a uma equipe de defesa priorizar incidentes verdadeiramente críticos (como a leitura do arquivo de senhas pelo IP `95.161.22.128`) em detrimento de ruídos inofensivos gerados por automações comuns de rede.

6.3 AVALIAÇÃO QUANTITATIVA DE CLASSIFICAÇÃO

Para consolidar a validação da ferramenta e mensurar matematicamente a sua eficácia em distinguir comportamentos maliciosos de ruídos operacionais, a arquitetura foi submetida a uma avaliação quantitativa rigorosa. Em sistemas de detecção de intrusão, a comprovação empírica por meio de métricas de *Machine Learning* é fundamental para atestar a confiabilidade dos vereditos gerados. O objetivo desta etapa foi avaliar se a inteligência artificial consegue cravar de forma assertiva a classificação final das entidades mapeadas como *ANÔMALO* ou *LEGÍTIMO*, confrontando suas predições com uma base de Verdade Terrestre (*Ground Truth*) previamente estabelecida a partir do *dataset* simulado.

No contexto da avaliação de inteligência artificial, o conceito de *Ground Truth* (Verdade Terrestre) refere-se ao gabarito irrefutável do conjunto de dados — ou seja, a classificação real, incontestável e conhecida *a priori* pelo pesquisador que modelou a simulação, definindo com exatidão quais entidades são de fato ofensores e quais representam tráfego benigno.

É importante ressaltar que o ensaio quantitativo não foi conduzido mediante a classificação linha a linha (registro por registro) do arquivo bruto. Essa decisão metodológica baseia-se na premissa de que um evento de *log* isolado, desprovido de histórico, frequentemente carece de semântica e valor diagnóstico suficientes para caracterizar um ataque de forma determinística. Portanto, a unidade de análise (e de classificação) adotada foi a "entidade"e sua respectiva linha do tempo.

Desse modo, o ensaio consistiu em submeter as janelas de contexto completas das entidades diretamente ao modelo Gemma 2. O desempenho do classificador foi tabulado em uma Matriz de Confusão, instrumento clássico que categoriza os acertos e erros do modelo em quatro quadrantes: Verdadeiros Positivos (VP), Verdadeiros Negativos (VN), Falsos Positivos (FP) e Falsos Negativos (FN). A partir destes valores, foram calculadas as métricas de Precisão, Sensibilidade (*Recall*) e *F1-Score*.

As equações subjacentes à avaliação de desempenho são definidas por:

$$\text{Precision} = \frac{VP}{VP + FP} \tag{6.1}$$

$$\text{Recall} = \frac{VP}{VP + FN} \tag{6.2}$$

$$\text{F1} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \tag{6.3}$$

O Quadro 6 apresenta a extração dos resultados consolidados após a execução da inferência sobre as entidades mapeadas no ambiente de testes.

Quadro 6 – Resultados das métricas de classificação quantitativa (Matriz de Confusão).

```
--- MATRIZ DE CONFUSÃO (Resultados Absolutos) ---
Verdadeiros Positivos (Ataques detectados): 1
Falsos Positivos (Alarmes falsos / Ruído alertado): 2
Verdadeiros Negativos (Tráfego normal aceito): 1
Falsos Negativos (Ataques omitidos): 0

--- MÉTRICAS DE DESEMPENHO ---
Precisão (Precision): 0.33
Sensibilidade (Recall): 1.00
F1-Score: 0.50
```

Fonte: Elaborado pelo autor (2026).

A análise dos números gerados pela avaliação quantitativa revela um comportamento crível e desejável no contexto de defesa cibernética. O indicador mais crítico para a eficácia de um ecossistema de segurança é a sua Taxa de Falsos Negativos. No ensaio realizado, o modelo obteve **0 Falsos Negativos**, culminando em uma Sensibilidade (*Recall*) de 1.00 (ou 100%). Isso significa que nenhuma ameaça real ou ataque contido na amostra testada passou despercebido pela camada cognitiva; o sistema garantiu a detecção do ofensor no momento em que seu histórico foi avaliado.

Em contrapartida, a obtenção de 2 Falsos Positivos reflete o "custo da segurança"em modelos heurísticos. A Precisão de 0.33 aponta que a inteligência artificial adotou uma postura conservadora e defensiva: ao deparar-se com linhas do tempo contendo anomalias estruturais ou comportamentos ruidosos de monitoramento, o modelo preferiu sinalizar a entidade como suspeita (alertando o analista humano) a assumir o risco de ignorar uma possível invasão.

Na prática operacional de um Centro de Operações de Segurança (SOC), um modelo "paranoico"que gera alguns alertas falsos acompanhados de justificativas textuais explícitas (XAI) é preferível a um sistema silencioso que permite a exfiltração de dados por falsos negativos. Os resultados matemáticos validam a eficácia da arquitetura proposta:

o classificador atua como uma barreira altamente sensível, entregando uma capacidade irrestrita de retenção de ameaças ao mesmo tempo em que fornece o contexto necessário para que o humano descarte os falsos positivos de forma célere.

6.4 AVALIAÇÃO QUALITATIVA DA ARQUITETURA COGNITIVA

Devido à natureza exploratória desta pesquisa e ao escopo do *dataset* gerado em ambiente de simulação, a avaliação da eficácia do modelo passa também por uma análise qualitativa do resultado. A principal contribuição dos LLMs neste cenário não reside na volumetria de processamento, mas na sua capacidade de correlação semântica avançada. Portanto, os resultados obtidos foram submetidos a uma avaliação fundamentada em três critérios práticos de validação técnica e operacional:

6.4.1 Fidelidade e Resiliência Semântica (Fase 1)

O primeiro critério de qualidade atesta a capacidade do modelo de reter informações críticas em cenários de alta entropia estrutural, o que pode ser um desafio para ferramentas tradicionais. Durante a execução da Fase 1, observou-se que o uso da técnica de *few-shot prompting* blindou o modelo contra quebras de tabelamento. Um exemplo prático de destaque ocorreu na extração do comando `nmap -sS -p 22,80,443`. Como o objetivo da Fase 1 é gerar um arquivo estruturado delimitado por vírgulas (formato CSV), ferramentas clássicas de particionamento de texto (*parsing*) frequentemente interpretam as vírgulas presentes no próprio comando como divisores de coluna, o que corrompe inteiramente o alinhamento da tabela. O modelo de linguagem, no entanto, aplicou sua compreensão semântica: ele reconheceu que a sequência `22,80,443` referia-se a uma lista de portas atrelada ao *payload* do atacante, e não à estrutura do arquivo. Com isso, o modelo encapsulou o comando inteiro na coluna correta, preservando a integridade da carga útil e garantindo que o contexto chegasse intacto à fase seguinte.

6.4.2 Aderência Tática a *Frameworks* de Segurança (Fase 2)

O segundo critério avalia se o julgamento da inteligência artificial está alinhado com a literatura de defesa cibernética. No Cenário B (Ameaça Interna, Quadro 3), o modelo não foi previamente programado com dicionários de ameaças rígidos. No entanto, por meio de seu raciocínio, ele demonstrou domínio dos conceitos da *Cyber Kill Chain*. A IA foi capaz de categorizar autonomamente o uso combinado de *shells* interativos (`/bin/bash`) e varreduras de rede (`nmap`) não apenas como uma anomalia estatística, mas como uma etapa de "Reconhecimento"e preparação para "Movimentação Lateral".

No contexto da segurança ofensiva, esse comportamento se define quando um atacante, após garantir acesso a um terminal para execução de comandos, utiliza o servidor comprometido como base para mapear a rede interna (Reconhecimento) em busca de outros

ativos vulneráveis, com o objetivo de pivotar seu ataque e expandir seu controle para novas máquinas dentro da infraestrutura (Movimentação Lateral). Esta capacidade de abstrair um *log* de texto isolado e mapeá-lo para uma tática de ataque eleva a taxonomia da detecção, aproximando-a da análise humana.

6.4.3 Qualidade da Explicabilidade e Redução de Carga Cognitiva

O terceiro e mais crítico (por ser o foco de nosso trabalho) eixo qualitativo afere a utilidade prática do artefato gerado para o operador humano. Em arquiteturas de "caixa-preta", o analista despende tempo considerável correlacionando eventos isolados para entender um alerta. A saída estruturada via *Chain of Thought* (CoT) provou possuir clareza e acionabilidade. Ao segmentar o veredito em "Evidências Observadas"e "Cadeia de Raciocínio", o modelo converteu os dados anômalos em relatórios forenses estruturados. De forma qualitativa, isso significa que a arquitetura atinge o seu objetivo principal: atenuar a assimetria informacional entre o invasor e o defensor, reduzindo a carga cognitiva do analista de SOC e viabilizando ações de contenção de forma rápida e precisa.

6.5 DISCUSSÃO: POTENCIAIS E CUSTOS OPERACIONAIS

A experimentação evidenciou que a segmentação do problema em um *pipeline* de duas fases mitiga significativamente o risco de colapso de contexto no modelo de linguagem. O uso de técnicas cognitivas como XAI reduz ativamente a fadiga de alertas (*alert fatigue*), pois os analistas do SOC não recebem notificações binárias (0 ou 1), mas sim narrativas embasadas, o que pode auxiliar o tomador de decisão, reduzindo o Tempo Médio de Resposta (*Mean Time to Respond* - MTTR).

Entretanto, sob a ótica da engenharia de computação, a solução impõe uma reflexão sobre restrições de infraestrutura e custos operacionais. A inferência textual baseada em LLMs, mesmo acelerada por GPUs (como a NVIDIA T4 utilizada), exige um processamento autorregressivo para a geração de *tokens* que é inerentemente mais pesado do que a execução de algoritmos determinísticos. Embora este trabalho não tenha focado em aferir métricas exatas de latência, a literatura estabelece que ferramentas baseadas em regras estáticas (como Regex) processam dados com custo computacional consideravelmente menor. A introdução desse custo de processamento (*overhead*) para a geração das narrativas explicativas reforça, de forma contundente, a necessidade da arquitetura híbrida adotada: a viabilidade da solução depende de delegar a filtragem volumétrica para ferramentas estatísticas rápidas, reservando o alto custo computacional da GPU exclusivamente para os incidentes que exigem análise cognitiva avançada.

Conclui-se, portanto, que na arquitetura tecnológica atual, a implementação deste *pipeline* é idealmente adequada para arquiteturas assíncronas — como investigações forenses *post-mortem*, auditorias de conformidade e análises detalhadas de incidentes já mapeados

por camadas de primeira linha — não substituindo um *firewall*, ou uma IDS ou IPS em linha operando na taxa de transferência em tempo real de um provedor de rede, mas ampliando a capacidade analítica das equipes de segurança cibernética.

6.6 SÍNTESE DA EFETIVIDADE DO PIPELINE

A implementação prática do modelo de pesos abertos Gemma 2 ao longo deste capítulo revelou que a segmentação do processamento cognitivo é vital para preservar a integridade analítica do sistema.

Na **Fase 1 (Destilação Semântica)**, o modelo substituiu com êxito a rigidez sintática das expressões regulares pela flexibilidade da compreensão semântica. A aplicação da técnica de *few-shot prompting* mitigou as alucinações e os erros de alinhamento tabular, permitindo que a IA convertesse dados ruidosos de alta entropia oriundos de um servidor Linux em registros estruturados. Essa redução de dimensionalidade provou ser um filtro eficiente, isolando entidades críticas e preservando o contexto operacional.

Na **Fase 2 (Inferência e Explicabilidade)**, a arquitetura demonstrou forte capacidade analítica comportamental. Ao examinar os dados estruturados de forma holística, a IA foi capaz de detectar tanto ataques clássicos de repetição temporal (Cenário A - Força Bruta) quanto ameaças internas e desvios comportamentais complexos (Cenário B - Movimentação Lateral via Nmap e Bash).

Ademais, a validação da arquitetura contra um histórico de maior volumetria (Cenário C) comprovou a viabilidade operacional do ecossistema por meio de uma abordagem de triagem híbrida. Ao utilizar algoritmos quantitativos clássicos de análise de frequência para isolar os maiores ofensores da rede, o motor cognitivo pôde focar seus recursos na geração de perfis qualitativos de ameaça. O uso da técnica de *Chain of Thought* (CoT) atendeu à premissa de Inteligência Artificial Explicável (XAI). O painel resultante entregou justificativas em linguagem natural, traduzindo anomalias matemáticas em narrativas forenses prontas para o consumo de analistas de segurança.

7 CONSIDERAÇÕES FINAIS

A complexidade e o volume das ameaças cibernéticas contemporâneas evidenciam o esgotamento das abordagens tradicionais de monitoramento baseadas puramente em assinaturas estáticas e expressões regulares (Regex). Diante do cenário de fadiga de alertas (*alert fatigue*) e da dificuldade em detectar movimentações laterais executadas com credenciais legítimas, este trabalho propôs, implementou e validou uma arquitetura de detecção de anomalias fundamentada em Inteligência Artificial Generativa.

O desenvolvimento do *pipeline* cognitivo em duas fases demonstrou ser uma abordagem arquitetural estruturada para a inserção de Modelos de Linguagem de Larga Escala (LLMs) em Centros de Operações de Segurança (SOCs).

7.1 ACHADOS PRÁTICOS

A partir dos testes realizados com o modelo Gemma 2 no *pipeline* cognitivo, foi possível extrair observações práticas fundamentais sobre o comportamento da Inteligência Artificial em cenários de defesa cibernética.

Primeiramente, no que tange ao **papel operacional do modelo**, constatou-se que a LLM não deve atuar como um mecanismo de filtragem de primeira linha (Como Firewall ou IPS), mas sim como um auditor analítico de segunda linha. O valor da ferramenta reside na sua capacidade de processar o contexto de janelas temporais e emitir laudos explicativos fundamentados, reduzindo o esforço de investigação forense do analista de SOC.

Em segundo lugar, a pesquisa validou a necessidade da **estratégia de *pipeline* híbrido**. O envio direto e ininterrupto de grandes volumes de registros brutos ao modelo inviabiliza a operação, não apenas pelo limite físico da janela de contexto, mas também pelo alto custo de alocação de memória (VRAM). A introdução da triagem quantitativa algorítmica (executada via biblioteca Pandas e tabelas de dispersão) provou ser um passo indispensável para isolar os ofensores estatísticos, garantindo que o modelo cognitivo consuma processamento apenas onde a avaliação qualitativa é necessária.

Por fim, a avaliação de eficácia revelou uma **postura conservadora** por parte do classificador. O ecossistema priorizou a mitigação de riscos, alcançando uma Sensibilidade (*Recall*) de 1.00 no experimento, garantindo a ausência de Falsos Negativos. Embora essa sensibilidade traga o ônus de gerar Falsos Positivos diante de ruídos operacionais atípicos, conclui-se que, no domínio da cibersegurança, essa postura defensiva é a mais adequada. A presença do painel de Inteligência Artificial Explicável (XAI), impulsionado pela Cadeia de Raciocínio (CoT), entrega o contexto necessário para que o operador humano audite e descarte os alertas falsos.

7.2 LIMITAÇÕES DO ESTUDO

Apesar dos resultados empíricos satisfatórios, a pesquisa identificou limitações operacionais inerentes à tecnologia atual de LLMs. A principal restrição reside no custo computacional e na latência de processamento. A execução do motor de inferência em Unidades de Processamento Gráfico (GPUs), como a NVIDIA T4, é sequencial e dependente da velocidade de geração de *tokens*. Consequentemente, o sistema desenvolvido atua de forma ótima em rotinas assíncronas — como auditorias retrospectivas, perícia forense e análise profunda de lotes de incidentes pré-filtrados — não sendo atualmente utilizado e recomendado para atuar como uma ferramenta preventiva de bloqueio em linha (*inline prevention*) sob fluxos massivos de tráfego de rede.

7.3 TRABALHOS FUTUROS

As descobertas e a base arquitetural estabelecidas por esta pesquisa direcionam as próximas investigações no domínio da segurança cibernética orientada por IA. Recomendam-se as seguintes frentes de expansão:

- ***Fine-Tuning* de Modelos Especializados:** Realizar o ajuste fino (*fine-tuning*) da arquitetura Gemma 2 utilizando exclusivamente *datasets* de *logs* de rede e descrições táticas da matriz MITRE ATT&CK. Isso permitiria a criação de um modelo menor e hiperespecializado, reduzindo a latência e o custo de inferência sem perder a capacidade explicativa.
- **Ingestão de Dados Multimodais:** Expandir a arquitetura do *pipeline* cognitivo para não apenas ingerir arquivos textuais (*logs*), mas também correlacionar eventos com dados de tráfego de rede em tempo real (PCAP) e telemetria de *endpoints* (EDR).
- **Automação de Resposta a Incidentes:** Integrar a saída da Fase 2 do sistema (o painel XAI) a plataformas de Orquestração, Automação e Resposta de Segurança (SOAR), permitindo que a IA não apenas identifique e explique a ameaça, mas recomende e execute rotinas de contenção (como o bloqueio dinâmico de conexões ou o isolamento do *host* comprometido).

O paradigma da segurança da informação encontra-se em uma transição definitiva. Este trabalho evidenciou que a convergência entre processamento de linguagem natural avançado e fluxos de trabalho de defesa cibernética tem o potencial de redefinir o monitoramento de infraestruturas, elevando os sistemas de segurança da mera detecção reativa para a real compreensão analítica das ameaças sistêmicas.

REFERÊNCIAS

AL-ALM, A. et al. Alert fatigue in cyber security: A systematic review. **IEEE Access**, v. 10, p. 10123–10140, 2022.

CHEN, Y. et al. Chain-of-thought reasoning in diffusion language models. **OpenReview**, 2024.

Google. **Gemma: Open Models Based on Gemini Technology**. [S.l.], 2024. Disponível em: <https://storage.googleapis.com/deepmind-media/gemma/gemma-report.pdf>.

GUDIVADA, V. N.; BAEZA-YATES, R.; RAGHAVAN, V. V. Cognitive computing: Concepts, architectures, systems, and applications. **Handbook of Statistics**, Elsevier, v. 33, p. 3–38, 2015.

GUNNING, D.; AHA, D. DARPA's explainable artificial intelligence (XAI) program. **AI Magazine**, v. 40, n. 2, p. 44–58, 2019.

HASSAN, M. et al. Explainable artificial intelligence in cyber defense - a review. **ResearchGate**, 2024.

HUTCHINS, E. M.; CLOPPERT, M. J.; AMIN, R. M. Intelligence-driven computer network defense informed by analysis of adversary campaigns and intrusion kill chains. In: **6th International Conference on Information Warfare and Security**. [S.l.: s.n.], 2011. p. 113–125.

ISLAM, M. T. et al. Bridging the gap: advancing the transparency and trustworthiness of network intrusion detection with explainable ai. **International Journal of Machine Learning and Cybernetics**, v. 15, n. 11, p. 5337–5360, 2024.

JOHNSON, C. et al. **Guide to Cyber Threat Information Sharing**. Gaithersburg, MD, 2016.

LI, J. et al. Fragile thoughts: How large language models handle chain-of-thought perturbations. **arXiv preprint arXiv:2603.03332**, 2024.

LIU, H. et al. Large language models empowered online log anomaly detection in aiops. **ResearchGate**, 2024.

NIST. **Guide to Computer Security Log Management**. Gaithersburg, MD, 2006.

SILVA, C.; BACELAR, K. **Pipeline Cognitivo para Detecção de Anomalias em Logs de Cibersegurança com Gemma 2**. [S.l.]: GitHub, 2026. <https://github.com/cassemanuel/tcc-gemma2-cybersecurity-log-analysis>. Acessado em: 20 jul. 2026.

SOMMER, R.; PAXSON, V. Outside the closed world: On explaining the difficulties of scalable network intrusion detection. In: **IEEE Symposium on Security and Privacy**. Oakland, CA: [s.n.], 2010. p. 37–52.

UDOFOT, A. I.; OLUSEYI, O. M.; BASSEY, E. Explainable ai for cyber security: Improving transparency and trust in intrusion detection systems. **International Journal of Advances in Engineering and Management**, v. 6, n. 12, p. 229–240, 2024.

VASWANI, A. et al. Attention is all you need. In: **Advances in Neural Information Processing Systems**. [S.l.]: Curran Associates, Inc., 2017. v. 30.

Verizon. **2023 Data Breach Investigations Report (DBIR)**. [S.l.], 2023.

WANG, X. et al. Llm-enhanced log anomaly detection: A comprehensive benchmark of large language models for automated system diagnostics. **arXiv preprint arXiv:2604.12218v1**, 2024.

ZEYANG, L. et al. LLM4Log: A survey of large language models for log analysis. **GitHub Repository**, 2024.

ZHANG, Z. et al. Multimodal-cot: Incorporating language and vision in two-stage frameworks. **arXiv preprint arXiv:2302.00923v5**, 2024.